



UNIVERSIDAD NACIONAL DE INGENIERÍA

FACULTAD DE CIENCIAS

ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN

*Conversión de voz en texto usando redes
neuronales*

SEMINARIO DE TESIS 2

Autor: Víctor Jesús Sotelo Chico

Asesor: Dr. Antonio Morán Cardenas

Diciembre, 2018

Resumen

En las últimas décadas el campo de la inteligencia artificial se ha desarrollado rápidamente. Estudios sobre reconocimiento de imágenes y voz han sido estudiados en las últimas décadas. Actualmente este campo requiere realizar un gran número de cálculos para entrenar redes neuronales que sean capaces de distinguir y clasificar distintos objetos contenidos en imágenes. Incluso este proceso puede tardar más dependiendo del tamaño del dataset. Por lo cual surge la necesidad de encontrar métodos que permitan acelerar el proceso de entrenamiento de las redes neuronales.

Por tal motivo presente seminario buscar lograr un mayor entendimiento de métodos para acelerar el proceso de entrenamiento de una red neuronal convolucional, basándonos en la teoría de redes neuronales y usando como herramienta la librería tensorflow, esta nos permite un uso controlado de los métodos de optimización.

KEYWORDS: Dataset, Métodos Adaptativos, CNN, SGD, Optimizadores.

Índice general

Resumen	III
1. Introducción	2
1.1. Motivación	2
1.2. Objetivos	4
1.3. Estructura del Seminario	5
2. Estado del Arte	6
2.1. Aprendizaje Automático	6
2.1.1. Uso de redes neuronales para encontrar el rendimiento de una GPU	6
2.1.2. Handshape recognition for Argentinian Sign Language using ProbSom	7
2.2. Aprendizaje Profundo	7
2.2.1. Deep Machine Learning - A New Frontier in Artificial Intelligence	7
2.2.2. On Optimization Methods for Deep Learning	8
2.3. Reconocimiento de Voz	8
2.3.1. Review of Algorithms and Applications in Speech Recognition System	8
2.3.2. SPEECH RECOGNITION WITH DEEP RECURRENT NEURAL NETWORKS	9
2.3.3. EFFICIENT CEPSTRAL NORMALIZATION FOR ROBUST SPEECH RECOGNITION	10
2.3.4. DELTA-SPECTRAL CEPSTRAL COEFFICIENTS FOR ROBUST SPEECH RECOGNITION	10

2.3.5.	Voice Recognition Algorithms using Mel Frequency Cepstral Coefficient (MFCC) and Dynamic Time Warping (DTW) Techniques	11
2.3.6.	Convolutional Neural Networks for Speech Recognition .	11
2.3.7.	TIME-FREQUENCY CONVOLUTIONAL NETWORKS FOR ROBUST SPEECH RECOGNITION	12
2.4.	Conclusiones	12
3.	Redes Neuronales Artificiales	13
3.1.	Conceptos básicos	13
3.1.1.	Neuronas	13
3.1.2.	Funciones de Activación	14
3.1.3.	Redes Neuronales Artificiales	15
3.2.	Redes Neuronales FeedFoward	16
3.2.1.	Algoritmo de propagación hacia atrás	17
3.3.	Redes Neuronales Convolucionales	18
3.3.1.	Estructura de una imagen	18
3.3.2.	Capas de una CNN	19
	Input layer	20
	Convolutional layers	20
	Pooling layers	22
	Fully Connected Layers	23
3.3.3.	Arquitecturas conocidas	23
3.4.	Redes Recurrentes	24
3.4.1.	Propagación hacia atrás través del tiempo(BPTT)	26
3.4.2.	Propagación dinámica hacia atrás (DBP)	28
3.4.3.	Desaparición de la gradiente	30
3.4.4.	Long Short Term Memory (LSTM)	31
4.	Procesamiento señal de voz	36
4.1.	Conceptos previos	36
4.1.1.	Voz	36

4.1.2.	Audios	36
4.1.3.	Espectro de frecuencias	37
4.1.4.	Escala mel	38
4.1.5.	Dominio de tiempo	38
4.1.6.	Dominio de frecuencia	38
4.2.	Proceso de extracción de características	39
4.2.1.	Etapas del proceso de extracción de características	39
	1. Análisis Espectral	39
	2. Transformación de parámetros	40
	3. Modelo estadístico	40
4.2.2.	Algoritmos	41
	Real Cepstral Coefficient(RCC)	41
	Mel Frequency Cepstral Coefficients (MFCC)	41
	Codificación lineal predictiva	44
4.3.	Coincidencia de patrones	44
	Modelo oculto de Markov (HMM)	44
	Máquinas de soporte Vectorial(SVM)	45
	Alineamiento temporal dinámico (DTW)	46
	Redes Neuronales	46
5.	Resultados	47
6.	Conclusiones y Trabajo Futuro	48
6.1.	Conclusiones	48
6.2.	Trabajo Futuro	48
A.	Arquitectura de la red y Resultados obtenidos	52
A.1.	Resultados de precisión de entrenamiento	52

Índice de figuras

3.1. Funciones de activación Fuente: https://ujjwalkarn.me	15
3.2. Redes neuronales biológicas y artificiales Fuente: https://medium.com	15
3.3. Esquema de Redes Neuronales FeedFoward Fuente: https://ujjwalkarn.me	16
3.4. Propagación hacia atrás Fuente: https://ujjwalkarn.me	17
3.5. Estructura de la imagen de entrada Fuente: <i>Deep Learning by Adam Gibson, Josh Patterson</i>	19
3.6. Operacion de convolución Fuente: www.openresearch.ai	21
3.7. Neurona Recurrente Fuente: https://medium.com	25
3.8. Versión desenrollada Fuente: https://towardsdatascience.com	25
3.9. BPTT Fuente: http://www.wildml.com	26
3.10. Función sigmoid y su derivada Fuente: https://medium.com	31
3.11. Estructura en cadena Fuente: http://colah.github.io	31
3.12. Unidad de LSTM Fuente: https://towardsdatascience.com	32
3.13. celda de estado Fuente: http://colah.github.io	32
3.14. capa sigmoideal Fuente: http://colah.github.io	33
3.15. capa tanh Fuente: http://colah.github.io	34
3.16. Actualización del C_t Fuente: http://colah.github.io	34
3.17. Calculo del h_t Fuente: http://colah.github.io	35
4.1. Onda de sonido Fuente: https://medium.com	37
4.2. señal de voz y su espectro asociado Fuente: https://www.finaltest.com.mx	37
4.3. Relación escala mel - Frecuencia Fuente: https://www.researchgate.net	38

4.4. Dominios de tiempo y frecuencia de dominio Fuente:	
<i>https://medium.com</i>	39
4.5. Etapas de extracción de características Fuente: <i>Fuente Propia</i> . . .	41
4.6. Aplicación del filtro Mel Fuente: <i>https://www.researchgate.net</i> . . .	43
4.7. Esquema del HMM Fuente: <i>http://gekkoquant.com</i>	44
4.8. transformación con la función kernel Fuente: <i>www.statsoft.com</i> . .	45
4.9. DTW Fuente: <i>https://lemonzi.files.wordpress.com</i>	46

Índice de Acrónimos

k-nn	k- nearest neighbors
SVM	Super Vector Machine
SVC	Super Vector Regression
SVR	Super Vector Classification
SGD	Stochastic gradient descent
DNN	Deep Neural Network
CNN	Convolutional Neural Network
ETC	Etcétera

Agradecimientos

Agradezco a mis padres por todo el apoyo incondicional durante todos estos años de estudio, a mis compañeros de clase por el apoyo brindado durante el tiempo de estudio y a mi asesor por ayudarme en este seminario.

Capítulo 1

Introducción

Dentro de la inteligencia artificial, las redes neuronales profundas desempeñan un papel muy importante, debido a que estas permiten entrenar a las computadoras para que realicen tareas que nuestros cerebros realizan de manera natural como el reconocimiento de voz, imágenes y patrones. Una característica de las redes neuronales profundas es la gran cantidad de capas que poseen. Esto permite que las redes sean capaces de extraer características de los datos ya sean imágenes o voz. La comunicación entre los seres humanos se realiza por medio del habla, la cual es emitida como una señal de voz debido a la cantidad de información que esta señal posee ha permitido el estudio y desarrollo de aplicaciones como identificadores biométricos, conversión de voz en texto, etc. Tareas como estas requieren un análisis complejo debido a que se necesita tratar problemas como la reverberación y el ruido presentes en el entorno.

1.1. Motivación

La inteligencia artificial constituye una base muy importante en el campo de la computación, esta mezcla un conjunto de disciplinas como la estadística y ciencia de la computación con el objetivo de construir modelos que puedan permitir a las computadoras realizar tareas que hace algunos años hubiesen sido consideradas imposibles. El avance de la inteligencia artificial ha permitido el desarrollo de programas que sean capaces de realizar tareas sin haber sido explícitamente programadas para hacerlas.

Entre los modelos existentes en la inteligencia artificial las redes neuronales han tenido un amplio desarrollo en las últimas décadas debido que sido utilizada para trata datos más complejos como las imágenes o señales de voz. El tratamiento de la voz es una tarea más compleja que ha sido estudiada en los últimos décadas debido a sus aplicaciones en la identificación biométrica, robótica y procesamiento de lenguaje natural.

Actualmente, los sistemas de reconocimiento de voz están presentes en distintos software muchos de ellos permiten romper algunas barreras presentes como por ejemplo en las personas con alguna discapacidad física existen software que permiten a las personas ciegas leer la pantalla de su computador transformando el texto en voz otro ejemplo son las personas sordas existen software capaces de transformar voz en texto.

Dentro del reconocimiento de voz existen problemas presentes como el ruido de voz y reverberación, fenómeno sonoro producido por la reflexión, los cuales deben considerados para que una red neuronal sea considera robusta ante estos problemas.

Además, debido a la gran cantidad de información que la señal de voz transmite es importante utilizar las herramientas adecuadas para reducir costo computacional ya sea mediante el uso de algoritmos eficientes o hardware más potentes.

En la actualidad existen APIs para el reconocimiento de voz pero estás siempre poseen limitaciones por lo cual en esta investigación se busca desarrollar un sistema de reconocimiento de voz que nos permita reconocer el habla y resuelva los problemas ya mencionados, es decir que sea robusta, esto nos permitirá entender y comprender como funciona el lenguaje humano. Este nuevo conocimiento nos permitirá desarrollar una red neuronal capaz de reconocer palabras del lenguaje español para luego procesar la voz y transformarla en texto.

1.2. Objetivos

El objetivo de este seminario es el diseñar un sistemas capaz de transformar la voz en texto mediante el uso de redes neuronales utilizando un conjunto de datos del lenguaje español.

Específicamente, los objetivos de este trabajo con respecto al sistema son:

- Entender el funcionamiento de las redes neuronales profundas.
- Conocer el proceso involucrado en el habla humana.
- Estudiar procesamiento de las señales de voz.
- Diseñar un sistema robusto capaz de reducir los problemas de reverberación y ruido.
- Mostrar los resultados obtenidos y explicarlos basándonos en la información estudiada.

Y los objetivos con respecto a las competencias académicas desplegadas en el trabajo son:

- Desarrollar un mejor entendimiento de las redes neuronales y sus aplicaciones, para así poder lograr afrontar problemas en el campo de la inteligencia artificial.
- Obtener la capacidad de discriminar entre los algoritmos para tratar las señales de voz.
- Desarrollar el criterio necesario para trabajar con datos de audio.
- Obtener un conocimiento de las herramientas y recursos que existen actualmente para abordar problemas de aprendizaje profundo, además de poder analizar que herramientas son adecuadas para algunos problemas.

1.3. Estructura del Seminario

- **Introducción:**

En este capítulo introductorio se comenta sobre el tema a tratar, las motivaciones, intereses, objetivos con los cuales se planteo el presente seminario.

- **Estado del Arte:**

Este capítulo muestra los trabajos e investigaciones ya realizadas, además de algunas aplicaciones que motivaron al presente seminario y además las investigaciones mostrarán el interés del problema planteado.

- **Redes Neuronales:**

En este capítulo daremos una introducción a las redes neuronales de manera general, además veremos los tipos de redes existentes y nos enfocaremos más en las redes neuronales recurrentes.

- **Procesamiento de la señal de voz**

En este capítulo conoceremos más el proceso del ingreso de la señal a nuestra red como. También describiremos los algoritmos usados en este proceso.

- **Resultados:**

Se mostrarán los resultados obtenidos en las pruebas de los optimizadores además de describir los resultados.

- **Conclusiones y Trabajo Futuro:**

En este capítulo se plantean las conclusiones y se detalla algunos inconvenientes encontrados durante el trabajo. Además que se comprueba la teoría descrita en el capítulo 3.

Capítulo 2

Estado del Arte

En este capítulo se describirán las investigaciones anteriores con relación al Aprendizaje Automático, además de sus aplicaciones. También se verán algunas investigaciones referente al reconocimiento de voz y los algoritmos usados para estas tareas.

Este trabajo también presentará investigaciones referentes a Aprendizaje Profundo, exclusivamente nos enfocaremos a la Redes Neuronales Convolucionales(CNN), ya que son parte del tema de estudio en la presente investigación.

2.1. Aprendizaje Automático

El uso del Aprendizaje Automático representa una gran ventaja para empresas que manejan gran cantidad de datos debido a que permiten descubrir patrones y analizar los datos.

2.1.1. Uso de redes neuronales para encontrar el rendimiento de una GPU

Un equipo conformado por investigadores [?]de AMD y The University of Texas at Austin, fueron quienes propusieron el uso de redes neuronales para predecir el rendimiento de una GPU. En la actualidad existen empresas dedicadas a la creación de GPUs, en el proceso una parte fundamental es la verificación del rendimiento de las GPUs. Actualmente existen simuladores

conocidos como GPGPU-SIM que permiten realizar estimaciones precisas pero estos presentan algunas dificultades como el tiempo empleado en configurarlos en base al hardware real, no obstante, este proceso se encuentra propenso a errores.

2.1.2. Handshape recognition for Argentinian Sign Language using ProbSom

Investigadores de la Universidad de La Plata, en Argentina conformado por Franco Ronchetti, Facundo Quiroga, César Estrebou, y Laura Lanzarini[1], desarrollaron un sistema que permite el reconocimiento de lenguaje de señas argentino. Esta investigación fue realizada usando una técnica llamada ProbSom, esta puede ser comparada con otros métodos como las Máquinas de Soporte Vectorial, Bosques Aleatorios y Redes Neuronales.

2.2. Aprendizaje Profundo

Dentro del área de Aprendizaje Automático encontramos Deep Learning o Aprendizaje Profundo el cual consiste en un conjunto de algoritmos que modela abstracciones de alto nivel.

En esta sección hablaremos de un paper que nos sirvió de una introducción al campo del aprendizaje profundo.

2.2.1. Deep Machine Learning - A New Frontier in Artificial Intelligence

Este trabajo de investigación fue realizado por investigadores Thomas Karnowski, Derek Rose - Oak Ridge National Laboratory y Itamar Arel - University of Tennessee [2], el objetivo principal de este trabajo fue presentarnos el aprendizaje profundo como un camino para la imitación del cerebro humano y sus principales cualidades como el reconocimiento de objetos, rostros, etc.

En este paper presenta una introducción a los temas de *Convolutional Neural Network*(CNN) y *Deep Belief Network*, nos describe a las CNN como una familia de redes neuronales multicapas que fueron diseñadas para tratar datos de dimensionalidad 2 como lo son las imágenes y los videos.

Por otro lado, también nos muestra las aplicaciones del aprendizaje profundo como: análisis de documentos, detección de voz, rostro, procesamiento natural del lenguaje, etc.

La aplicación de la inteligencia artificial no solo despierto en los investigadores, también existen algunas empresas privadas que apoyan el campo del Aprendizaje Profundo con el objetivo de buscar sus aplicaciones comerciales, entre estas empresas tenemos a: Numenta y Binatix.

2.2.2. On Optimization Methods for Deep Learning

Un equipo de la Universidad de Standford realizó unas pruebas con el objetivo de encontrar métodos adecuados para un entrenamiento en aprendizaje profundo. El equipo se percató de lo común que resulta el uso de gradiente de descenso estocástica (SGD por sus siglas en inglés) en aprendizaje profundo . Se realizaron pruebas con otros métodos de optimización como la gradiente conjugada y Limited memory BFGS(L-BFGS) los cuales permitieron acelerar el proceso de entrenamiento de algoritmos de Aprendizaje Profundo mostrando en su mayoría mejores resultados que el SGD. “Usando L-BFGS el modelo CNN alcanza el 0.69 % en el estándar del MNIST dataset.”[3]

2.3. Reconocimiento de Voz

2.3.1. Review of Algorithms and Applications in Speech Recognition System

Este trabajo fue realizado por CR Rashmi del *Cork Institute of Technology* (CIT) en la investigación se describe el reconocimiento del habla como

un método poder realizar distintas aplicaciones como: reconocimiento del hablante (Identificación Biométrica), emociones, acento, etc. Además se presentan distintos algoritmos que usan transformada de Fourier y modelos probabilísticos que son aplicados a tareas de reconocimiento de voz.

Esta investigación se centra en los algoritmos para la extracción de características y coincidencia de patrones.

Entre principales algoritmos para la extracción de características que muestran tenemos: RCC, MFCC, LPC, etc. Siendo el MFCC uno de los mejores para realizar tareas de reconocimiento del hablante. Por otro lado en coincidencia de patrones tenemos algoritmos como VQ, HMM, SVM, MLP, GMM, etc. Para tareas de reconocimiento de emociones y géneros destaca el GMM.

2.3.2. SPEECH RECOGNITION WITH DEEP RECURRENT NEURAL NETWORKS

Esta investigación realizada por los investigadores Alex Graves, Abdel-rahman Mohamed y Geoffrey Hinton de la Universidad de Toronto. El principal objetivo de esta investigación fue utilizar las redes neuronales recurrentes para el reconocimiento de fonemas utilizando el conjunto de datos TIMIT, el uso de las redes neuronales resulta adecuado debido a la naturaleza dinámica del habla.

El tipo de entrenamiento utilizado fue *end-to-end training* además se utilizan distribuciones diferenciales para todas las posibles salidas fonéticas. Entre los métodos estudiados para estas distribuciones de salida tenemos *Connectionist Temporal Classification (CTC)* este método decide si emitir una etiqueta de acuerdo al fonema identificado o no emitirla.

“Las redes neuronales entrenadas con CTC son generalmente bidireccionales para asegurar que la distribución de salida dependa únicamente de la secuencia de entrada”. Otro método estudiado en esta investigación de RNN transducir el cual predice un fonema dado uno previo. En la experimentación fueron usados 2 reguladores *parada temprana* y *pesos de ruidos*. “CLC se obtiene un

porcentaje de error de 23.9 % a 18.4 % a medida que se aumentan los niveles ocultos de la red. ”

2.3.3. EFFICIENT CEPSTRAL NORMALIZATION FOR ROBUST SPEECH RECOGNITION

Esta investigación estuvo a cargo de Fu-Hua Liu, Richard M. Stern, Xuedong Huang y Alejandro Acero del departamento de ingeniería eléctrica e informática de la Universidad de Carnegie Mellon. El objetivo de esta investigación fue comparar los procedimientos basados en cepstrum usados en el reconocimiento de voz sobre variedad de entornos acústicos.

Para los autores “Los estudios muestran que los sistemas de reconocimiento de voz que son diseñados para ser independientes del hablante funcionan de manera incorrecta cuando se prueban distintos micrófonos o entornos con los cuales fueron entrenados ”. Una solución a este problema es la aplicación de técnicas de normalización cepstral como *SNR-Dependent Cepstral Normalization (SDCN)*, *Fixed Codeword-Dependent Cepstral Normalization (FCDCN)* y *Multiple fixed codeword-dependent cepstral normalization (MFCDCN)*.

Entre el FCDCN y MFCDCN este último resulta ser mejor debido a que no requiere del entrenamiento del específico como lo hace el FCDCN.

2.3.4. DELTA-SPECTRAL CEPSTRAL COEFFICIENTS FOR ROBUST SPEECH RECOGNITION

El presente paper fue realizado por Kshitiz Kumar , Chanwoo Kim y Richard M. Stern del departamento de ingeniería eléctrica e informática de la Universidad de Carnegie Mellon. En esta investigación se busca diseñar un sistema de reconocimiento de voz más robusto mediante el uso de las características delta-espectrales. En palabra de los autores “ *A pesar que las características delta cepstrales capturan la información dinámica y mejoran la precisión del reconocimiento de voz no son robustos contra el ruido y reverberación.*”

2.3.5. Voice Recognition Algorithms using Mel Frequency Cepstral Coefficient (MFCC) and Dynamic Time Warping (DTW) Techniques

Esta investigación fue realizada por Lindasalwa Muda, Mumtaj Begam y I. Elamvazuthi, en esta se describen los principios involucrados en el reconocimiento de voz como la extracción de características y patrones. Al igual que otras investigaciones los autores afirman *“La voz es una señal de infinita información. Un análisis directo y sintetizado es requerido para la gran cantidad de señal contenida en la señal.”*

El reconocimiento de voz puede ser dividido en 2 fases una fase de entrenamiento en que el hablante provee información o muestras de su voz y una fase de testeo donde se verifica que la voz de entrada coincida con la del hablante del proceso de entrenamiento. Los investigadores utilizan MFCC para la extracción de características y DTW para reconocimiento de los patrones. En las pruebas de identificación se logró encontrar una distorsión óptima en DTW que permitió reconocer al hablante.

2.3.6. Convolutional Neural Networks for Speech Recognition

Entre los distintos modelos existentes en redes neuronales profundas ha surgido la necesidad de realizar modelos híbridos como *Deep Neural Network-Hidden Markov Model(DNN-HMM)* y *Gaussian Mixture Model - Hidden Markov Model(GMM-HMM)*. La presente investigación encontró que la primera es más robusta debido a la capacidad que poseen las redes neuronales al momento de modelar correlaciones complejas de las características de la voz.

Los resultados mostraron que usando CNN se obtuvo una mejora de 6-10 % en tareas de phone recognition y búsqueda de voz en un gran vocabulario.

2.3.7. TIME-FREQUENCY CONVOLUTIONAL NETWORKS FOR ROBUST SPEECH RECOGNITION

Este estudio usa a las redes neuronales convolucionales profundas(DCNN) para generar una arquitectura más robusta contra el ruido y otras variaciones del entorno. DCNN usa los filtros de convolución para así poder remover las distorsiones cross-spectral una cualidad de este tipo de red es que no utiliza la convolución sobre el tiempo. Por lo cual esta convolución es trata en esta investigación definiendo un esquema llamado time-frequency convolutional network (TFCNN), esta red aplica 2 capas de convolución paralelas una para la frecuencia y otra para el tiempo.

En las pruebas realizadas se nota una mejora al probar con ruidos, canales y datos dañados con reverberación a comparación del uso de DCNN.

2.4. Conclusiones

A medida que tratamos muchos problemas vemos la necesidad de encontrar optimizadores adecuados para los diferentes tipos de problemas. En el área de Aprendizaje Profundo comúnmente se trabaja en el campo de reconocimiento de imágenes.

A pesar de las mejoras mediante el uso de GPUs este tipo de problemas necesitan soluciones óptimos para obtener un mejor rendimiento. Métodos como Nesterov Momentum, RMSProp y Adam surgen como principales opciones para realizar optimizaciones de la gradiente de descenso.

Capítulo 3

Redes Neuronales Artificiales

En este capítulo daremos una introducción a las redes neuronales artificiales veremos su uso en el aprendizaje automático para tareas de clasificación y además estudiaremos 2 tipos especiales de redes neuronales como son las *redes convolucionales y recurrentes*.

En este seminario se dará más énfasis a las redes recurrentes y su aplicación en el procesamiento de voz para lograr la tarea de conversión voz a texto.

3.1. Conceptos básicos

A continuación describiremos algunos conceptos necesarios para el entendimiento de las redes neuronales artificiales más adelante se mostrarán nuevos de acuerdo al tipo de red.

3.1.1. Neuronas

En la biología, la neurona es conocida como la unidad fundamental del cerebro humano, el cual está compuesto por millones de neuronas interconectadas entre si(sinapsis). El trabajo de las neuronas consiste en recibir información, procesarla y enviarla a otras neuronas.

Este modelo fue copiado en 1943 por Warren S. McCulloch y Walter H. Pitts para poder diseñar un neurona artificial que es análoga a las neuronas del cerebro humano, esta neurona artificial tomará una cantidad n de entradas $x_1, x_2, x_3, \dots, x_n$ las entradas serán multiplicadas(producto interno) por pesos

$w_1, w_2, w_3, \dots, w_n$ además se puede añadir una constante que llamaremos bias(b) para producir un salida.

La entrada a la neurona será la suma total de los productos $z = \sum_{i=1}^n w_i x_i + b$, el valor de z , esta se evaluará con una función f de tal forma que nuestra salida será $y = f(z)$.

En la ecuación 3.1 observamos la misma salida expresada en forma vectorial para nuestros vectores $x = [x_1 x_2 x_3 \dots x_n]$ y $w = [w_1 w_2 w_3 \dots w_n]$

$$y = f(x \cdot w + b) \quad (3.1)$$

3.1.2. Funciones de Activación

La función f mencionada anteriormente es una función no lineal, conocida como **función de activación**.

La tarea principal de la función de activación es introducir no linealidad a la salida de una neurona. Esto es importante debido a que la vida real no trabajamos solo con datos lineales y de esta forma la neurona puede aprender representaciones no lineales.

Entre funciones de activación tenemos algunas comúnmente usada como:

- **Sigmoid:** Toma un valor real, y lo transforma en un valor en el rango de 0 a 1.

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

- **tanh:** Toma por entrada un valor real y lo transforma a un número en el rango de -1 a 1.

$$\tanh(x) = \frac{2}{1+e^{-x}} - 1$$

- **ReLU:** o Unidad lineal rectificada es una función que para valores menores que 0 asigna 0 y para valores mayores

$$f(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases}$$




FIGURA 3.1: Funciones de activación

Fuente: <https://uijwalkarn.me>

3.1.3. Redes Neuronales Artificiales

Las redes neuronales artificiales(ANN) toman la arquitectura del cerebro como inspiración para la construcción de sistemas inteligentes. Actualmente son la base para el desarrollo de la inteligencia artificial.

Una red neuronal está constituida por las uniones de neuronas.

En la figura 3.10 podemos ver la comparación entre una neurona biológica y un artificial etiquetadas con A y B respectivamente. Además observamos que las redes neuronales artificiales (etiqueta D) imitan el la unión biológicas de las neuronas o sinapsis(Etiqueta C).




FIGURA 3.2: Redes neuronales biológicas y artificiales

Fuente: <https://medium.com>

3.2. Redes Neuronales FeedFoward

Estas redes fueron de las primeras y más simples. Contienen múltiples neuronas (nodos) ordenadas en capas de modo que los nodos en capas adyacentes se conectan. Cada una de estas conexiones poseen un peso asociado a dicha conexión.

En la figura 3.3 mostramos el esquema de Redes FeedFoward con sus distintas capas(layer).




FIGURA 3.3: Esquema de Redes Neuronales FeedFoward

Fuente: <https://ujjwalkarn.me>

- **Nodo de entrada(Input Node):** Proveen información a la red. En conjunto representan la capa de entrada, ningún calculo es realizado en esta capa solo se transfiere la información a la capa oculta.
- **Nodo Oculto(Hidden Node):** El trabajo de los nodos ocultos es calcular y transferir la información hacia a el nodo de salida. Una Red FeedFoward tiene solo una capa de entrada y una salida pero puede tener múltiples capas ocultas.
- **Output Node:** Su tarea principal es realizar cálculos y transferir la información fuera de la red.

En las Redes Neuronales FeedFoward, la información solo se propaga en una dirección hacia *adelante* desde los nodos de entradas pasando por los nodos ocultos hacia los nodos de salida. No existen ciclos en este tipo de red.

Dentro de las redes neuronales FeedFoward tenemos algunos ejemplos:

- **Perceptron Simple:** Es un red prealimentada simple que no posee capa oculta. Solo puede aprender de funciones lineales.
- **Perceptron Multicapas:** Esta red posee una o más capas ocultas. Este perceptron puede aprender de funciones no lineales.
- **Redes neuronales de convolución:** Este tipo de redes neuronal será explicada más adelante en el capítulo.

3.2.1. Algoritmo de propagación hacia atrás

El algoritmo de propagación hacia atrás trata de aprender de los errores, en el aprendizaje supervisado los conjuntos de entrenamiento se encuentran etiquetados. Por lo cual podemos sabemos la salida esperada.

El algoritmos se aplica de la siguiente forma:

1. Se toma un ejemplo y se asignan pesos aleatorios a todas las conexiones de la red. Luego por medio de las conexiones y funciones de activación se calcula la salida en las capas ocultas y de salida.
2. Se calcula el error total y se propagan estos errores hacia atrás a través de la red y se calcula la gradiente, luego se usan métodos como gradientes de descenso para ajustar los pesos y reducir el error en la capa de salida.
3. Se repite el proceso con los otros ejemplos

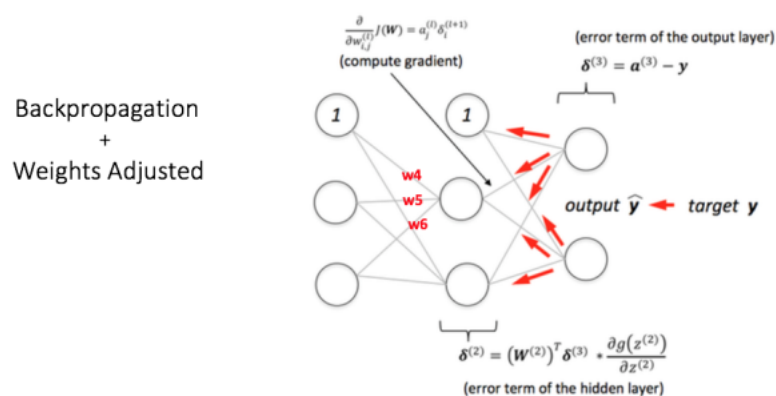


FIGURA 3.4: Propagación hacia atrás

Fuente: <https://ujjwalkarn.me>

3.3. Redes Neuronales Convolucionales

Las CNN son un tipo de Redes Neuronales FeedFoward que son especiales para procesar datos como imágenes las cuales son más difíciles de tratar en una red neuronal tradicional, como por ejemplo en el caso del perceptron multicapas.

El término *convolucional* hace referencia a la operación lineal matemática usada. Las redes neuronales convolucionales usan esta operación para aprender de las características de mayor orden presente en los datos. La primera CNN fue creada por Yann LeCun. Estas redes neuronales fueron inspiradas en la corteza visuales de los animales. Las células de la corteza visual, estas se activan para realizar tareas como el reconocimiento de patrones.

Entre sus usos más comunes tenemos el reconocimiento de imágenes y lenguaje natural.

3.3.1. Estructura de una imagen

Debido a que las redes neuronales convolucionales son usadas comúnmente con imágenes, es importante conocer cual es la estructura de una imagen y cómo es que la computadora comprende y utiliza esta información.

Las imágenes están constituidas por una sucesión de píxeles, podemos entender el pixel como la menor unidad homogénea en color de una imagen digital. Teniendo este concepto, podemos dividir la información de una imagen de la siguiente forma:

- **Width:** El ancho de la imagen medido en pixeles
- **Height:** El alto de la imagen medida en pixeles.
- **Canales RGB:** Estos canales contiene la información de los colores y profundidad de una imagen. Este canal guarda la información en tres canales Red, Green y Blue.




FIGURA 3.5: Estructura de la imagen de entrada
Fuente: *Deep Learning by Adam Gibson, Josh Patterson*

Teniendo en cuenta esta forma de dividir la información de una imagen podemos resaltar la ventaja de usar Redes convolucionales en lugar de usar una red neuronal multicapas.

Las redes multicapas toman un vector de una dimensión como entrada, si quisiéramos entrenar un perceptron multicapas con imágenes de 32x32 píxeles y con 3 canales RGB necesitaríamos crear 3072 pesos (w_i) para una sola neurona en la capa oculta. Esta generación excesiva de peso hace que la tarea resulte complicada usando redes multicapas.

De esta forma surge la idea de recurrir a un tiempo tipo de redes neuronales que faciliten la tarea sin consumir muchos recursos.

3.3.2. Capas de una CNN

Las redes neuronales convoluciones pueden ser divididas en distintas capas, cada una de ellas con una tarea específica para el tratamiento de la información. En esta sección describiremos cada una de estas capas.

Input layer

Esta capa es la encargada de cargar y almacenar la información de las imágenes para luego procesarlas en la red. Esta información contiene detalles de ancho, alto en píxeles y el número de canales de imagen. Las entradas de esta capa corresponden a la imagen vista en la figura 3.5.

Convolutional layers

Es una de las capas más importante en el diseño de las CNNs, esta capa es la encargada de transformar la entrada(imagen o convolución anterior) usando las conexiones de las neuronas en capas anteriores.

Para entender más a fondo esta capa debemos definir la operación de *convolución*.

La *convolución* es una operación matemática que describe una regla de como fusionar 2 conjuntos de información. “Esta operación tiene importancia en campos como la matemática y la física debido que permite definir un puente entre el dominio del espacio/tiempo y el dominio de la frecuencias a través del uso de la transformada de fourier. La convolución toma una entrada, aplica un kernel de convolución y nos da un mapa de características como salida ”[4] .

Las convoluciones son usadas principalmente como un detectores de características cuyas entradas son la capa de entrada u otra convolución. En la figura 3.6 observamos la operación de convolución que por medio del uso de un kernel o filtro de convolución extrae características de la imagen, por ejemplo detalles como bordes de una imagen.

Haciendo analogía con los pesos en las redes neuronales convencionales, las redes convolucionales poseen el *filtro o kernel* , esto resulta beneficioso, ya que no se tendrá definir un peso para cada neurona.

El kernel de la figura 3.6 será desplazado a lo largo de las dimensiones espaciales. Durante el desplazamiento, el kernel se multiplicará por los datos de entrada dentro de su limite, produciendo una sola salida al mapa de características.




FIGURA 3.6: Operación de convolución

Fuente: www.openresearch.ai

Las capas convolucionales aplican transformaciones o funciones de activación al conjunto de entrada, luego el mapa de activación generado se apilará a lo largo de dimensión de profundidad para construir el volumen de salida.

Componentes de la capa de convolución.

Las capas convolucionales poseen parámetros e hiperparámetros. La gradiente de descenso tiene la función de entrenar a estos parámetros de modo que las clases sean consistentes con las etiquetas en el conjunto de entrenamiento. Entre estos parámetros tenemos: **Filtros**

Los filtros son una función que posee ancho(width) y alto (height) más pequeños que la entrada. Los filtros son aplicados a través de del ancho y alto de la entrada, pero también pueden ser aplicados a lo largo de la profundidad.

Hiperparámetros de una capa de convolución.

A continuación veremos algunos hiperparámetros que determinan la disposición espacial y tamaño del volumen de salida de una capa convolucional.

- **Filter size:** Cada filtro es pequeño con respecto al ancho(width) y alto(height) del la capa anterior. Por ejemplo podemos tener un filtro de tamaño $[5 \times 5 \times 3]$, lo representa 5 de ancho x 5 de alto x 3 de los canales RGB.
- **Output depth:** Este hiperparámetro controla el número de neuronas en la capa convolucional que están conectadas al mismo del volumen de entrada. Este parámetro puede ser elegido manualmente.
- **Stride:** Se encarga de configurar el tamaño de desplazamiento de la ventana de filtro. Cada filtro aplicado a la columna de entrada asignará más profundidad en el volumen de salida. Un stride grande creará un volumen de salida más grande y uno valor pequeño obtendrá un volumen menor.
- **Zero-padding:** Con este parámetro se puede controlar el volumen de salida. Es usado para mantener el tamaño espacial de entrada en la salida.

Pooling layers

Este tipo de capas se encuentran entre las capas convolucionales. Se encarga de reducir el tamaño espacial(ancho,alto) de los datos de representación. Esta capa reduce la representación de los datos progresivamente a través de la red y ayuda a controlar el *overfitting*.

Esta capa utiliza la operación $\max()$ para cambiar el tamaño de los datos de entrada espacialmente, a esta operación se le conoce como max pooling. Esta funciona de siguiente forma toma un filtro de $n \times n$, y la operación \max toma el mayor de los números en el área de filtro.

Por ejemplo en caso tener una imagen de entrada 32×32 píxeles y se aplica un filtro de 2×2 , como resultado obtendremos una salida de 16×16 píxeles. Esto reduce cada segmento de profundidad en el volumen de entrada por un factor de 2.

Fully Connected Layers

Esta capa se calcula el puntaje de las clases que usaremos como salida de red, esta será la encargada de reconocer a que clase pertenece una imagen de prueba de acuerdo a su puntaje o probabilidad. Las dimensiones del volumen de la salida son $[1 \times 1 \times N]$, donde el valor de N corresponde al número de clases de salida que se están evaluando. En el caso del MNIST (dataset para reconocimiento de dígitos), el valor de N es igual a 10, número que corresponde a los 10 dígitos distintos que posee el dataset(0, ..., 9).

Esta capa tiene conexión entre todas sus neuronas y las de la capa anterior. Esta capa realiza las transformaciones del volumen de datos de entrada. Estas son funciones de activación en el volumen de entrada y los parámetros (pesos y bias de las neuronas).

3.3.3. Arquitecturas conocidas

Actualmente existen algunas arquitecturas de CNN ya diseñadas que son aplicadas para el trabajo de reconocimiento de imágenes.

El proyecto ImageNet, posee una gran base de datos de imágenes. Este proyecto realizó una competición llamada *ImageNet Large Scale Visual Recognition Challenge (ILSVRC)* donde compiten distintos programas de software para detectar y clasificar objetos.

A continuación mostraremos algunas de las arquitecturas más importante de esta competencia:

- **LeNet-5 (1998)** “Arquitectura propuesta por LeCun, consiste 2 capas de convolución, activación y capas pooling seguidas por a fully conected layer”[5]
- **AlexNet (2012)** Fue propuesta por Alex Krizhevsky, esta arquitectura posee 5 capas de convolución seguida por 3 fully connected layers.
- **VGGNet (2014)** Fue desarrollada para Sigmoyan y Zisserman para la competición ILSVRC. “VGG consta de 16 capas convolucionales y es muy atractivo debido a su arquitectura uniforme. Consta de convoluciones de 3x3 y utiliza múltiples filtros ”[6]

3.4. Redes Recurrentes

Las redes neuronales recurrentes aparecieron en los años 1980s, actualmente se han desarrollado más estudios debido a la mejora de hardware. Son utilizadas principalmente para tratar con una información de secuencia, por ejemplo series de tiempo, audio, sentencia de oraciones, etc.

La principal diferencia de la redes con las redes neuronales feed-foward es que en las neuronas de las redes recurrentes las salidas regresan a la entrada de esta manera mantiene información de un estado anterior. Esto permite que nuestro modelo sea cambiante cada vez que este se alimente con una secuencia nueva.

Dentro de una capa recurrente se tiene los siguientes tipos de conexiones :

- **Entrantes:** Son aquellas que emanan de la capa previa.
- **Salientes:** Estas conexiones son dirigidas a todas las neuronas de las capas consecuentes.
- **Recurrentes:** se encargan de propagar la información entre las neuronas de las misma capa.




FIGURA 3.7: Neurona Recurrente

Fuente: <https://medium.com>

Es posible representar a la redes recurrentes como si fueran redes feed-fowards esto lo realizamos *desenrollando* la neurona como vemos en la figura 3.8 el x_t representa un estado final de esta forma podemos representar la red como un conjunto de estados a través de un lapso de tiempo. En esta forma las técnicas de backpropagation pueden ser usadas en la redes recurrentes.




FIGURA 3.8: Versión desenrollada

Fuente: <https://towardsdatascience.com>

3.4.1. Propagación hacia atrás través del tiempo(BPTT)

Las redes neuronales feedforward, la propagación hacia atrás se encarga de transmitir el error de la salida hacia a las capas ocultas asignados a los pesos(w) responsabilidad del error general mediante el uso de la derivada parcial $\frac{\partial E}{\partial w}$. En estas redes es común usar la propagación hacia atrás debido a que el par entrada salida posee un tamaño fijo situación que no ocurre con las secuencia de datos.

Las redes neuronales recurrentes utilizan una extensión de la propagación hacia atrás llamada *Propagación hacia atrás a través del tiempo*, o BPTT por sus siglas en inglés, la cual se aplica para secuencia de datos. Este algoritmo consta de los siguiente pasos:

- Dado unos lapsos de tiempo entre la entrada y la salida de la red.
- Se desenrolla la red(Ver Figura 3.8) , calcula y acumulada los errores de cada lapso de tiempo.
- Enrolla la red y actualiza los pesos para reducir el error.

“Si la secuencia de datos consta de 1000 lapsos de tiempo, este será el número de derivadas requeridas para una simple actualización ”[7]




FIGURA 3.9: BPTT
Fuente: <http://www.wildml.com>

En este esquema de básico de redes neuronales recurrentes utilizamos la función de activación softmax para calcular los valores de la celda y utilizamos pesos (U, W, V) de esta forma tenemos que:

$$\begin{aligned} s_t &= \tanh(Ux_t + Ws_{t-1}) \\ \hat{y}_t &= \text{softmax}(Vs_t) \end{aligned} \quad (3.2)$$

Donde s_t son los valores de la celda y \hat{y}_t es la predicción. A continuación calcularemos el error de nuestra red utilizando el valor de la predicción \hat{y}_t y el valor real y_t .

$$\begin{aligned} E_t(y_t, \hat{y}_t) &= y_t \log y_t \\ E_t(y, \hat{y}) &= \sum_t E_t(y_t, \hat{y}_t) \end{aligned} \quad (3.3)$$

Nuestro objetivo será ajustar los pesos (U, W, V) por lo cual usaremos la gradiente de descenso con respecto a los pesos los cuales serán calculados en la ecuación 3.4.

$$\frac{\partial E}{\partial W} = \sum_t \frac{\partial E_t}{\partial W} \quad (3.4)$$

Para calcula esta gradiente haremos uso de la regla de la cadena para simplificar los cálculos usaremos un ejemplo el E_t para $t = 2$.

$$\begin{aligned} \frac{\partial E_2}{\partial V} &= \frac{\partial E_2}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial V} \\ \frac{\partial E_2}{\partial V} &= \frac{\partial E_2}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial z_2} \frac{\partial z_2}{\partial V} \\ \frac{\partial E_2}{\partial V} &= (\hat{y}_2 - y_2) \otimes s_3 \end{aligned} \quad (3.5)$$

Donde $s_2 = Vs_3$ ahora calcularemos para W como $s_2 = \tanh(Ux_t + Ws_1)$ Al derivar obtenemos la ecuación 3.6 luego se sumarán las contribuciones en cada lapso de tiempo.

$$\frac{\partial E_2}{\partial W} = \frac{\partial E_2}{\partial \hat{y}_2} \frac{\partial \hat{y}_2}{\partial s_2} \frac{\partial s_2}{\partial s_k} \frac{\partial s_k}{\partial W} \quad (3.6)$$

3.4.2. Propagación dinámica hacia atrás (DBP)

Este algoritmo fue propuesto por Pineda[8] en 1987. Este tipo de redes neuronales son utilizados a las redes neuronales dinámica, la cual esta representada por la ecuación no lineal de tiempo discreto mostrará en la ecuación 3.7

$$\begin{cases} x(k+1) = f(x(k), W, \theta) \\ y(k) = h(x(k)) \end{cases} \quad (3.7)$$

- $x = [x_1, \dots, x_n]^T$: Vector de estado de la red dinámica
- x_i : estado interno de la neurona i
- $W = [w_{ij}]_{n \times n}$: Matriz de valores de pesos.
- $\theta = [\theta_1, \dots, \theta_n]^T$: vector somático.
- $f : R^n \times R^{n \times n} \times R^n \rightarrow R^n$ función continua y diferenciable.
- $h(x) : R^n \rightarrow R^m$ función continua y diferenciable.

Para el caso de redes recurrentes se tienen conexiones hacia adelante y hacia atrás entre las capas y las neuronas. Ahora los pesos w_{ij} representa la conexión sináptica entre la i -ésima y j -ésima y θ_i umbral en la i -ésima neurona.

$$\begin{cases} x_i(k+1) = f_i(x(k), w_i, \theta_i) \\ y(k) = h(x(k)) \end{cases} \quad (3.8)$$

Donde :

$$W = \begin{bmatrix} w_{11} & w_{12} & w_{13} & \dots & w_{1n} \\ w_{21} & w_{22} & w_{23} & \dots & w_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & w_{n3} & \dots & w_{nn} \end{bmatrix} = \begin{bmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_d^T \end{bmatrix} \quad (3.9)$$

$$w_i = \begin{bmatrix} w_{i1} \\ w_{i2} \\ \vdots \\ w_{in} \end{bmatrix} \quad i = 1, 2, \dots, n \quad (3.10)$$

La ecuación 3.7 nos muestra que el comportamiento dinámico de la neurona depende los pesos (w_{ij}) y el parámetro θ_i . Dado $t = [t_1, \dots, t_m]^T$ un valor objetivo de nuestra red y nuestro propósito es encontrar los valores de pesos adecuados para estimar $t = h(x^f)$. De esta forma podemos definir el error en la ecuación 3.11.

$$E = \frac{1}{2} \sum_{l=1}^m [t_l - h_l(x^f)]^2 = \frac{1}{2} \sum (J_l^f)^2 \quad (3.11)$$

Donde $J_l^f = t_l - h_l(x^f)$

A continuación veremos como se actualizarán los parámetros w_{ij} y θ_i usando tasa de aprendizaje η_w y η_θ respectivamente.

$$\begin{aligned} \Delta w_{ij} &= -\eta_w \frac{\partial E}{\partial w_{ij}} \\ &= \eta_w \sum_{p=1}^n \sum_{l=1}^m [t_l - h_l(x^f)] \frac{\partial h_l(x^f)}{\partial x_p^f} \frac{\partial x_p^f}{\partial w_{ij}} \\ &= \eta_w \sum_{p=1}^n \sum_{l=1}^m J_l^f \frac{\partial h_l(x^f)}{\partial x_p^f} \frac{\partial x_p^f}{\partial w_{ij}} \end{aligned} \quad (3.12)$$

$$\begin{aligned} \Delta \theta_i &= -\eta_\theta \frac{\partial E}{\partial \theta_i} \\ &= \eta_\theta \sum_{p=1}^n \sum_{l=1}^m [t_l - h_l(x^f)] \frac{\partial h_l(x^f)}{\partial x_p^f} \frac{\partial x_p^f}{\partial \theta_i} \\ &= \eta_\theta \sum_{p=1}^n \sum_{l=1}^m J_l^f \frac{\partial h_l(x^f)}{\partial x_p^f} \frac{\partial x_p^f}{\partial \theta_i} \end{aligned} \quad (3.13)$$

Derivando las ecuaciones 3.12 y 3.13

$$\begin{aligned} \Delta w_{ij} &= -\eta_w z_i^f \frac{\partial f_i(x^f, w_i, \theta_i)}{\partial w_{ij}} \\ \Delta \theta_i &= -\eta_\theta z_i^f \frac{\partial f_i(x^f, w_i, \theta_i)}{\partial \theta_i} \end{aligned} \quad (3.14)$$

Donde z_i^f esta determinada por la siguiente ecuación:

$$z_i^f = \sum_{p=1}^n \frac{\partial f_p}{\partial x_i^f} z_p^f + \sum_{l=1}^m J_l^f \frac{\partial h_l(x^f)}{\partial x_i^f} \quad (3.15)$$

“Un algoritmo de propagación dinámica hacia atrás es utilizado para entrenar la red en configuraciones de bucle cerrado, cuando existe una ruta de retroalimentación entre la salida de la sección de filtro digital y las entradas a la red neuronal.”[9]

3.4.3. Desaparición de la gradiente

Las redes recurrentes ofrecen una gran ventaja al manejar *secuencias de datos* pero el trabajar con este tipo de datos también pueden repercutir en un problema conocido como la desaparición de la gradiente, o *Vanishing Gradient*, el cual es una de la principales dificultades en las redes recurrentes.

La gradiente de descenso nos permite actualizar los valores de nuestros pesos para que nuestra red continúe aprendiendo, pero si esta gradiente desaparece, debido a que toma un valor pequeño, nuestra red deja de aprender en términos sencillos en esto consiste el problema de *desaparición de gradiente*.

Dado que en la propagación hacia atrás se calcula la gradiente usando la regla de la cadena podemos suponer que usamos la función sigmoid de la figura 3.9 notamos que su derivada para valores positivos y negativos grandes toma el valor de 0 lo que producirá que la gradiente desaparezca y nuestra red deje de aprender al no poder actualizar.

Entre la soluciones para este problema se encuentran usar otras funciones de activación como Relu o Elu, también se pueden usar métodos de normalización para los batchs.




FIGURA 3.10: Función sigmoid y su derivada

Fuente: <https://medium.com>

3.4.4. Long Short Term Memory (LSTM)

LSTM es un tipo de red neuronal recurrente que fue propuesto por Sepp Hochreiter y Jurgen Schmidhuber.[10] para aprovechar las ventajas de las redes recurrentes y combatir el problema de la desaparición de gradiente.

En la redes recurrentes se transmite la información pero ha medida que transcurre el tiempo están son olvidadas, a esto se le llamó el *problema de las dependencias a largo plazo*. Las LSTM buscan solucionar este problema, por lo cual estas se encargan de transmitir la información y *recordarla* mientras los lapsos de tiempo pasan imitando la *capacidad de la memoria humana para recordar*.




FIGURA 3.11: Estructura en cadena

Fuente: <http://colah.github.io>

En la siguiente figura observamos el esquema de una unidad, o neurona, de LSTM y estudiaremos su comportamiento.




FIGURA 3.12: Unidad de LSTM
Fuente: <https://towardsdatascience.com>

- X_t : entrada actual
- σ : capa sigmoid
- \tanh : capa tanh
- h_{t-1} : salidas de la última unidad.
- C_{t-1} : memoria de la última unidad.
- h_t : salida actual.
- C_t : memoria actualizada

Principalmente la idea de LSTM gira entorno a las celdas de estado c_t , esta será la encargada de añadir nueva información o removerla si ya no es necesaria.




FIGURA 3.13: celda de estado
Fuente: <http://colah.github.io>

El valor de la celda de estado(C_t) y la salida(h_t) :

1. Nuestro LSTM decidirá que información será desechada de nuestra célula de estado. Esta decisión utilizará una capa sigmoideal llamada *forget gate layer* la cual genera un número entre 0 y 1, lo cual definirá la cantidad de información que mantendrá.




FIGURA 3.14: capa sigmoideal

Fuente: <http://colah.github.io>

$$f_t = \sigma(W_t \cdot [h_{t-1}, x_t] + b_f) \quad (3.16)$$

2. Una vez que se ha olvidado es importante es aceptar nueva información y almacenarla. Esto será realizado en los siguientes pasos.
 - a) Una capa sigmoid llamada *input gate layer* decide que valores serán actualizados(i_t).
 - b) Una capa tanh crea un vector de valores posibles, o valores candidatos, \hat{C}_t .




FIGURA 3.15: capa tanh
Fuente: <http://colah.github.io>

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3.17)$$

$$\hat{C}_t = \sigma(W_C \cdot [h_{t-1}, x_t] + b_C)$$

c) Finalmente se combinan ambos para actualizar la celda de estado.


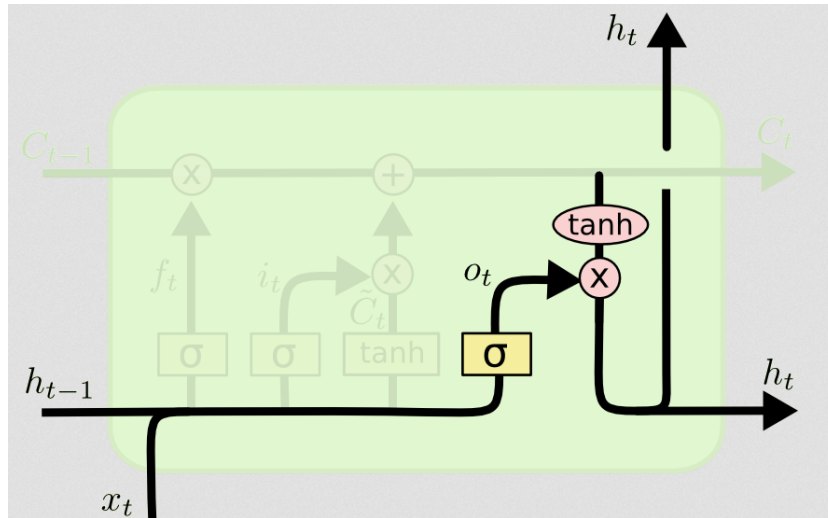


FIGURA 3.16: Actualización del C_t
Fuente: <http://colah.github.io>

$$C_t = f_t * C_{t-1} + i_t * \hat{C}_t \quad (3.18)$$

3. Finalmente para obtener la salida de este módulo C_t

FIGURA 3.17: Calculo del h_t Fuente: <http://colah.github.io>

$$\begin{aligned}
 o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o) \\
 h_t &= o_t * \tanh(C_t)
 \end{aligned}
 \tag{3.19}$$

Una variante de las redes recurrentes son las redes recurrentes bidireccionales, la cual consiste en aprender de una secuencia de datos en 2 direcciones siguiendo lapsos de tiempo de la secuencia hacia adelante y atrás. Al capturar la información de la secuencia invertida nos permite mejorar nuestra predicción. “Para superar las limitaciones de una RNN regular proponemos un modelo bidireccional de redes recurrentes(BRNN) la cual puede ser entrenada con la información de entrada en el pasado y en el futuro de un marco específico de tiempo ”[11]

Capítulo 4

Procesamiento señal de voz

En este capítulo conoceremos más acerca del procedimiento para procesar la señal de voz, además repasaremos algunos conceptos previos para entender en procesamiento y luego introduciremos 2 conceptos importantes *Extracción de características y la coincidencia de patrones*.

4.1. Conceptos previos

4.1.1. Voz

Los seres humanos diariamente nos comunicamos por medio del habla utilizando nuestras voces somos capaces de transferir información en forma de *ondas sonoras*.

Estas ondas transmiten una gran cantidad de información usando el aire como medio de transmisión. Las propiedades como variaciones en amplitud al empezar o finalizar una palabra varían en el transcurso del tiempo, por lo cual es importante analizar segmentos de tiempo donde estas propiedades se mantengan aisladas de esta manera nos aseguramos que la señal de voz no cambie.

4.1.2. Audios

Los audios son un tipo de *datos no estructurados*, es decir datos que no se encuentran en algún tipo de estructura de datos, estos tipos de datos son los que más se encuentran en el mundo real como imágenes y audio. Una característica de

estos es que son complejos en su recolección y preparación para la realización de un análisis.

El audio puede capturarse mediante la grabación de nuestro entorno pero para que este audio sea entendido por las computadoras necesita un formato adecuado como: wav, mp3 y wma.

Debido a que el sonido es una señal de onda podemos analizar y obtener valores numéricos de este. En la figura 4.1 observamos una onda de la cual obtenemos valores almacenando las alturas de puntos equidistantes de esta forma guardamos información de esta onda.




FIGURA 4.1: Onda de sonido

Fuente: <https://medium.com>

4.1.3. Espectro de frecuencias

Consiste en la distribución de amplitudes para un valor dado de frecuencia de un fenómeno ondulatorio en este caso ondas sonoras.




FIGURA 4.2: señal de voz y su espectro asociado

Fuente: <https://www.finaltest.com.mx>

4.1.4. Escala mel

Es una escala psicoacústica propuesta por Stevens, Volkman y Newman. Esta escala es muy importante debido a que la representación más usada en las señales de voz.

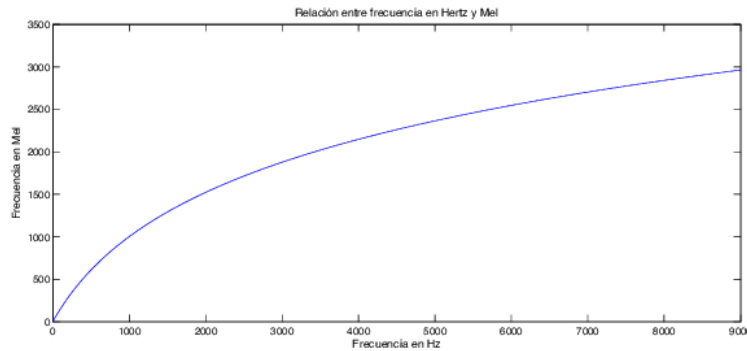


FIGURA 4.3: Relación escala mel - Frecuencia

Fuente: <https://www.researchgate.net>

$$m = 1127.01048 \log_e(1 + f/700)) \quad (4.1)$$

4.1.5. Dominio de tiempo

Este dominio permite obtener la amplitud en un instante de tiempo dado existen dominio de tiempo discretos y continuos.

4.1.6. Dominio de frecuencia

Este dominio permite representar a nuestra frecuencia de onda como un par de amplitud y valores de la fase. Para señales periódicas se relaciona con series de fourier y para señales no periódicas se relaciona con la transformada de fourier.




FIGURA 4.4: Dominios de tiempo y frecuencia de dominio

Fuente: <https://medium.com>

4.2. Proceso de extracción de características

También conocido como análisis de la señal de voz este proceso retiene la información necesaria de la voz y elimina los datos redundantes y no necesarios. Este proceso es uno de los más importantes debido a que se transforma la señal en una forma adecuada para los modelos de clasificación.

4.2.1. Etapas del proceso de extracción de características

El proceso de extracción de características puede ser dividido en 3 etapas o subprocesos.

1. Análisis Espectral

El análisis espectral consiste en descomponer algo complejo en parte o identificar propiedades de la muestra analizada. Cuando tratamos con una señal de voz esta es variable en el tiempo, por tanto podemos identificar sus características en función a la actividad espectral. El análisis espectral puede ser realizado usando los siguientes métodos:

- **Banco de filtros digitales**

Es un sistema que divide una señal de entrada $x(n)$ en un conjunto de señales x_1, x_2, \dots donde cada una corresponde a una región del espectro de $x(n)$.

■ Transformada de fourier

Dada una señal aperiódica discreta en el tiempo $x(n)$ definimos la transformada discreta de Fourier como:

$$X(k) = \sum_{n=0}^{N-1} x(n) \exp^{-j2\pi k \frac{n}{N}} \quad k = 0, \dots, N-1 \quad (4.2)$$

Esta transformada es calculada por la transformada rápida de Fourier, esta tiene el objetivo de encontrar los componente de la frecuencia en una señal ruidosa dentro de su dominio de frecuencia.

■ Predicción Lineal

La predicción Lineal o LP, es una técnica para modelar el espectro de la señal de voz por medio de los espectros de todos los polos. “El método permite la conformación espectral arbitraria en el dominio de la frecuencia y el modelado de espectros continuos y discretos.”[12]

2. Transformación de parámetros

Los parámetros son generados mediante operaciones fundamentales como: diferenciación y concatenación. La salida será un vector de parámetros con estimaciones brutas de la señal.

3. Modelo estadístico

En este paso se asume que de los parámetros de las señales son producidas por procesos aleatorios multivariados. En este proceso lo único que conocemos es la entrada(parámetros) y la salida. Los vectores de los parámetros son conocidos como observaciones de señales y es usado para determinar si son parte de una palabra, frase o representan un ruido.

En la figura 4.5 mostramos el proceso que siguen algunos algoritmos de extracción de características.

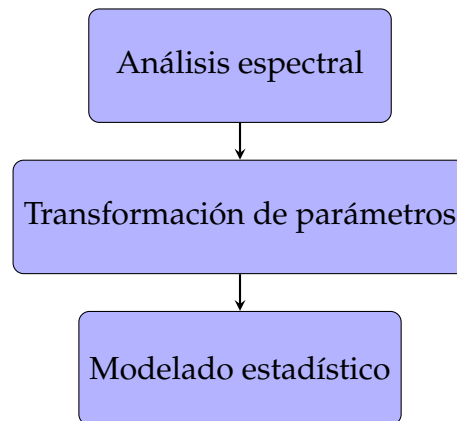


FIGURA 4.5: Etapas de extracción de características
Fuente: *Fuente Propia*

4.2.2. Algoritmos

A continuación describiremos algunos algoritmos que se usan para realizar este proceso.

Real Cepstral Coefficient(RCC)

Este algoritmo convierte la señal del dominio de tiempo a dominio de frecuencia aplicando la transformada rápida de fourier a cada cuadro(frame). Luego se aplica el logaritmo y la transformada de fourier inversa.

$$RealCepstrum = IFFT(\log(FFT(s(n)))) \quad (4.3)$$

Donde:

- IFFT: Transformada de fourier inversa
- FFT: transformada rápida de fourier.
- $s(n)$: señal de voz.

Mel Frequency Cepstral Coefficients (MFCC)

Es el algoritmo más usado en aplicaciones de reconocimiento de voz, esta basado en el sistema auditivo humano, el cual es sensible a 2

características dinámicas y estáticas. El MFCC se concentra principalmente en las características estáticas. A continuación describiremos el proceso de la MFCC.

1. Pre-emphasis

En este paso la señal pasa a través de un filtro el cual enfatiza las altas frecuencia. Este proceso aumentará la potencia de la señal con mayor frecuencia.

2. Framing

Se realiza la segmentación de la señal de voz digital, es decir la señal es dividida en pequeños intervalos(*frames*), estos generalmente son del rango de 20ms a 30ms.

3. Hamming windowing

Se utiliza como una forma de ventana que trabajo con los bloques de la cadena de extracción de características y tiene la finalidad de integrar las frecuencias más cercanas.

$$Y(n) = X(n)xW(n) \quad (4.4)$$

$$W(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right) 0 \leq n \leq N$$

- $Y(n)$: Señal de salida
- $W(n)$: Hamming window
- $X(n)$: Señal de entrada
- N : Número de ejemplo en cada frame

4. Transformada rápida de Fourier

Se encarga de transformar las muestras N del dominio de tiempo al dominio de frecuencia.

$$Y(w) = FFT(H(t) * X(t)) = H(w) * X(w) \quad (4.5)$$

- $Y(w)$: Transformada de Fourier de $Y(t)$

- $H(w)$: Transformada de Fourier de $H(t)$
- $X(w)$: Transformada de Fourier de $X(t)$

5. Mel filter bank

Debido a que el rango en el espectro de la Transformada rápida de Fourier es muy amplia y la señal de voz no sigue una escala lineal.

La ecuación 4.5 se usa para calcular Mel para una frecuencia de tiempo.

$$F(mel) = (2595 * \log_{10}(1 + f/700)) \quad (4.6)$$




FIGURA 4.6: Aplicación del filtro Mel

Fuente: <https://www.researchgate.net>

6. Discrete Cosine Transform (DCT)

Este proceso se encarga de convertir el log del espectro Mel en un dominio de tiempo usando DCT. El resultado es llamado MFCC. El conjunto de coeficientes es llamado vectores acústicos.

7. Delta energy and Delta spectrum

La señal de voz junto con los cambios de frames necesitan añadir características relacionadas a los cambios en las características cepstrales sobre el tiempo. La energía en un frame de tiempo t_1 a t_2 está dado por:

$$Energia = \sum X^2(t) \quad (4.7)$$

Codificación lineal predictiva

Este método también conocido como LCP considera que la señales de voz pueden ser expresadas como la combinación lineal de las anteriores, entonces podemos describir a la señal de voz utilizando los coeficientes de esta combinación lineal. Este método ha sido utilizado para el procesamiento de la señal de voz debido modela el comportamiento del tracto vocal.

En el ecuación 4.3 vemos como se expresa la señal de voz s usando las p anteriores señales de voz y los a_k representan *coeficientes del LCP*.

$$s(n) = \sum_{k=1}^p a_k s(n-k) + e(n) \quad (4.8)$$

4.3. Coincidencia de patrones

A continuación se describirán algunos algoritmos usados para las tareas de las coincidencias de patrones.

Modelo oculto de Markov (HMM)

Es un modelo estadístico donde asumimos que nuestro sistema es un proceso de markov con parámetros desconocidos. A continuación se describirá el proceso en la figura 4.7




FIGURA 4.7: Esquema del HMM

Fuente: <http://gekkoquant.com>

- N: Número de estados en el HMM
- a_{ij} probabilidad de transición del estado i al j .

- $b_j(o)$ Probabilidad de generar un vector de característica en estado j .

Máquinas de soporte Vectorial(SVM)

Las SVM usan el concepto de planos de decisión. Un plano de decisión separa un conjunto de objetos que tienen diferentes etiquetas de clases. Las SVM no están restringidas a los problemas lineales debido a las *funciones Kernel*.

Funciones Kernels

Las SVM pueden tener distintos tipos de kernels que tienen como objetivo tomar la data y transformarla. Algunas funciones kernels conocidas:

- Lineal: $\ker(x_i, x_j) = x_i \cdot x_j$
- Polinomial: $\ker(x_i, x_j) = (\gamma x_i \cdot x_j + C)^d$
- Radial: $\ker(x_i, x_j) = e^{(\gamma |x_i - x_j|)}$
- Sigmoidal: $\ker(x_i, x_j) = \tanh(\gamma x_i \cdot x_j + C)$

En la figura 4.7 muestra el efecto de las funciones kernels en un conjunto de datos para que este sea linealmente separable sin necesidad de construir curvas complejas.




FIGURA 4.8: transformación con la función kernel

Fuente: www.statsoft.com

Alineamiento temporal dinámico (DTW)

Es un método de programación dinámica que busca encontrar una alineación óptima entre 2 series de tiempo. El algoritmo trata de buscar deformaciones entre las series de tiempo y determina la similitudes entre ambas series. Esto nos permite tener una robustez en caso de grupos fonéticos en el audio tenga una duración más prolongada.

En la figura 4.6 se muestra 2 series de tiempo donde se trazan las coincidencias entre ambas series.




FIGURA 4.9: DTW
Fuente: <https://lemonzi.files.wordpress.com>

Redes Neuronales

Las redes neuronales descritas en el capítulo 3, luego de su entrenamiento serán capaces de reconocer los patrones de las señales de voz.

Capítulo 5

Resultados

Capítulo 6

Conclusiones y Trabajo Futuro

En este capítulo se describirán las conclusiones generales

6.1. Conclusiones

6.2. Trabajo Futuro

Bibliografía

- [1] César Estrebow Franco Ronchetti, Facundo Quiroga and Laura Lanzarini. Handshape recognition for argentinian sign language using probsom. *JCST*, 16(1):1–5, 2010.
- [2] Derek Rose Itamar Arel and Thomas Karnowski. Deep machine learning - a new frontier in artificial intelligence research [research frontier]. *JCST*, 16(1):1–5, 2010.
- [3] Adam Coates Abhik Lahiri Bobby Prochnow Quoc V. Le, Jiquan Ngiam and Andrew Y. Ng. On optimization methods for deep learning. *International Conference on Machine Learning 2010*, pages 1–8, 2010.
- [4] Josh Patterson and Adam Gibson. Major architectures of deep networks. In *Deep Learning A Practitioner's Approach*, pages 132–135. O'Reilly Media, 2017.
- [5] Adrian Rosebrock. Lenet – convolutional neural network in python. <https://www.pyimagesearch.com/2016/08/01/lenet-convolutional-neural-network-in-python>, Ago 2016. Accessed on 2018-06-15.
- [6] Siddharth Das. Cnn architectures: Lenet, alexnet, vgg, googlenet, resnet and more https://medium.com/@siddharthdas_32104/cnns-architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5, Nov 2017. Accessed on 2018-06-15.
- [7] Jason Brownlee. A gentle introduction to backpropagation through time. <https://machinelearningmastery.com/gentle->

- introduction-backpropagation-time/, Jun 2017. Accessed on 2018-10-11.
- [8] Fernando J. Pineda. Generalization of back-propagation to recurrent neural networks. *PHYSICAL REVIEW LETTERS*, 59(19):2229–2232, 1987.
- [9] Janos Sztipanovit. Dynamic backpropagation algorithm for neural network controlled resonator-bank architecture. *IEEE TRANSACTIONS ON CIRCUITS AND SYSTEMS-11: ANALOG AND DIGITAL SIGNAL PROCESSING*, 39(2):99–108, 1992.
- [10] Sepp Hochreiter and Jurgen Schmidhuber. Long short-term memory. In *Neural Computation*, pages 1735–1780, 1997.
- [11] M. Schuster and K. Paliwal. Bidirectional recurrent neural networks. *IEEE TRANSACTIONS ON SIGNAL PROCESSING*, 45(11):2673–2681, 1997.
- [12] J. Makhoul. Spectral linear prediction: Properties and applications. *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 23:283–296, 1975.

Apéndice A

Arquitectura de la red y Resultados obtenidos

A.1. Resultados de precisión de entrenamiento