



# UNIVERSIDAD NACIONAL DE INGENIERÍA

FACULTAD DE CIENCIAS

ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN

*Conversión de voz en texto usando redes  
neuronales*

## SEMINARIO DE TESIS 2

*Autor: Víctor Jesús Sotelo Chico*

*Asesor: Antonio Morán Cardenas*

Diciembre, 2018



# *Resumen*

En las últimas décadas el campo de la inteligencia artificial se ha desarrollado rápidamente. Estudios sobre reconocimiento de imágenes y voz han sido estudiados en las últimas décadas. Actualmente este campo requiere realizar un gran número de cálculos para entrenar redes neuronales que sean capaces de distinguir y clasificar distintos objetos contenidos en imágenes. Incluso este proceso puede tardar más dependiendo del tamaño del dataset. Por lo cual surge la necesidad de encontrar métodos que permitan acelerar el proceso de entrenamiento de las redes neuronales.

Por tal motivo presente seminario buscar lograr un mayor entendimiento de métodos para acelerar el proceso de entrenamiento de una red neuronal convolucional, basándonos en la teoría de redes neuronales y usando como herramienta la librería tensorflow, esta nos permite un uso controlado de los métodos de optimización.

**KEYWORDS:** Dataset, Métodos Adaptativos, CNN, SGD, Optimizadores.



# Índice general

<b>Resumen</b>	<b>III</b>
<b>1. Introducción</b>	<b>1</b>
1.1. Motivación . . . . .	1
1.2. Objetivos . . . . .	3
1.3. Estructura del Seminario . . . . .	4
<b>2. Estado del Arte</b>	<b>5</b>
2.1. Aprendizaje Automático . . . . .	5
2.1.1. Uso de redes neuronales para encontrar el rendimiento de una GPU . . . . .	5
2.1.2. Handshape recognition for Argentinian Sign Language using ProbSom . . . . .	6
2.2. Aprendizaje Profundo . . . . .	6
2.2.1. Deep Machine Learning - A New Frontier in Artificial Intelligence . . . . .	6
2.2.2. On Optimization Methods for Deep Learning . . . . .	7
2.3. Reconocimiento de Voz . . . . .	7
2.3.1. Review of Algorithms and Applications in Speech Recognition System . . . . .	7
2.3.2. SPEECH RECOGNITION WITH DEEP RECURRENT NEURAL NETWORKS . . . . .	8
2.3.3. EFFICIENT CEPSTRAL NORMALIZATION FOR ROBUST SPEECH RECOGNITION . . . . .	9
2.3.4. DELTA-SPECTRAL CEPSTRAL COEFFICIENTS FOR ROBUST SPEECH RECOGNITION . . . . .	9

2.3.5. Voice Recognition Algorithms using Mel Frequency Cepstral Coefficient (MFCC) and Dynamic Time Warping (DTW) Techniques . . . . .	10
2.3.6. Convolutional Neural Networks for Speech Recognition .	10
2.3.7. TIME-FREQUENCY CONVOLUTIONAL NETWORKS FOR ROBUST SPEECH RECOGNITION . . . . .	11
2.4. Conclusiones . . . . .	11
<b>3. Redes Neuronales Artificiales</b>	<b>12</b>
3.1. Conceptos básicos . . . . .	12
3.1.1. Neuronas . . . . .	12
3.1.2. Funciones de Activación . . . . .	13
3.1.3. Redes Neuronales Artificiales . . . . .	14
3.2. Redes Neuronales FeedFoward . . . . .	15
3.2.1. Algoritmo de propagación hacia atrás . . . . .	16
3.3. Redes Neuronales Convolucionales . . . . .	17
3.3.1. Estructura de una imagen . . . . .	17
3.3.2. Capas de una CNN . . . . .	18
Input layer . . . . .	19
Convolutional layers . . . . .	19
Pooling layers . . . . .	21
Fully Connected Layers . . . . .	22
3.3.3. Arquitecturas conocidas . . . . .	22
3.4. Redes Recurrentes . . . . .	23
<b>4. Procesamiento señal de voz</b>	<b>26</b>
<b>5. Resultados</b>	<b>27</b>
<b>6. Conclusiones y Trabajo Futuro</b>	<b>28</b>
6.1. Conclusiones . . . . .	28
6.2. Trabajo Futuro . . . . .	28

<b>A. Arquitectura de la red y Resultados obtenidos</b>	<b>33</b>
A.1. Resultados de precisión de entrenamiento . . . . .	33

# Índice de figuras

3.1. Funciones de activación Fuente: <i><a href="https://ujjwalkarn.me">https://ujjwalkarn.me</a></i> . . . . .	14
3.2. Redes neuronales biológicas y artificiales Fuente: <i><a href="https://medium.com">https://medium.com</a></i> . . . . .	14
3.3. Esquema de Redes Neuronales FeedFoward Fuente: <i><a href="https://ujjwalkarn.me">https://ujjwalkarn.me</a></i> . . . . .	15
3.4. Propagación hacia atrás Fuente: <i><a href="https://ujjwalkarn.me">https://ujjwalkarn.me</a></i> . . . . .	16
3.5. Estructura de la imagen de entrada Fuente: <i>Deep Learning by Adam Gibson, Josh Patterson</i> . . . . .	18
3.6. Operacion de convolución Fuente: <i><a href="http://www.openresearch.ai">www.openresearch.ai</a></i> . . . . .	20
3.7. Neurona Recurrente Fuente: <i><a href="https://medium.com">https://medium.com</a></i> . . . . .	24
3.8. Versión desenrollada Fuente: <i><a href="https://medium.com">https://medium.com</a></i> . . . . .	24



# Índice de Acrónimos

<b>k-nn</b>	k- nearest neighbors
<b>SVM</b>	Super Vector Machine
<b>SVC</b>	Super Vector Regression
<b>SVR</b>	Super Vector Classification
<b>SGD</b>	Stochastic gradient descent
<b>DNN</b>	Deep Neural Network
<b>CNN</b>	Convolutional Neural Network
<b>ETC</b>	Etcétera



# *Agradecimientos*

Agradezco a mis padres por todo el apoyo incondicional durante todos estos años de estudio, a mis compañeros de clase por el apoyo brindado durante el tiempo de estudio y a mi asesor por ayudarme en este seminario.



# Capítulo 1

## Introducción

Dentro de la inteligencia artificial, las redes neuronales profundas desempeñan un papel muy importante, debido a que estas permiten entrenar a las computadoras para que realicen tareas que nuestros cerebros realizan de manera natural como el reconocimiento de voz, imágenes y patrones. Una característica de las redes neuronales profundas es la gran cantidad de capas que poseen. Esto permite que las redes sean capaces de extraer características de los datos ya sean imágenes o voz. La comunicación entre los seres humanos se realiza por medio del habla, la cual es emitida como una señal de voz debido a la cantidad de información que esta señal posee ha permitido el estudio y desarrollo de aplicaciones como identificadores biométricos, conversión de voz en texto, etc. Tareas como estas requieren un análisis complejo debido a que se necesita tratar problemas como la reverberación y el ruido presentes en el entorno.

### 1.1. Motivación

La inteligencia artificial constituye una base muy importante en el campo de la computación, esta mezcla un conjunto de disciplinas como la estadística y ciencia de la computación con el objetivo de construir modelos que puedan permitir a las computadoras realizar tareas que hace algunos años hubiesen sido consideradas imposibles. El avance de la inteligencia artificial ha permitido el desarrollo de programas que sean capaces de realizar tareas sin haber sido explícitamente programadas para hacerlas.

Entre los modelos existentes en la inteligencia artificial las redes neuronales han tenido un amplio desarrollo en las últimas décadas debido que sido utilizada para trata datos más complejos como las imágenes o señales de voz. El tratamiento de la voz es una tarea más compleja que ha sido estudiada en los últimos décadas debido a sus aplicaciones en la identificación biométrica, robótica y procesamiento de lenguaje natural.

Actualmente, los sistemas de reconocimiento de voz están presentes en distintos software muchos de ellos permiten romper algunas barreras presentes como por ejemplo en las personas con alguna discapacidad física existen software que permiten a las personas ciegas leer la pantalla de su computador transformando el texto en voz otro ejemplo son las personas sordas existen software capaces de transformar voz en texto.

Dentro del reconocimiento de voz existen problemas presentes como el ruido de voz y reverberación, fenómeno sonoro producido por la reflexión, los cuales deben considerados para que una red neuronal sea considera robusta ante estos problemas.

Además, debido a la gran cantidad de información que la señal de voz transmite es importante utilizar las herramientas adecuadas para reducir costo computacional ya sea mediante el uso de algoritmos eficientes o hardware más potentes.

En la actualidad existen APIs para el reconocimiento de voz pero estás siempre poseen limitaciones por lo cual en esta investigación se busca desarrollar un sistema de reconocimiento de voz que nos permita reconocer el habla y resuelva los problemas ya mencionados, es decir que sea robusta, esto nos permitirá entender y comprender como funciona el lenguaje humano. Este nuevo conocimiento nos permitirá desarrollar una red neuronal capaz de reconocer palabras del lenguaje español para luego procesar la voz y transformarla en texto.

## 1.2. Objetivos

El objetivo de este seminario es el diseñar un sistemas capaz de transformar la voz en texto mediante el uso de redes neuronales utilizando un conjunto de datos del lenguaje español.

Específicamente, los objetivos de este trabajo con respecto al sistema son:

- Entender el funcionamiento de las redes neuronales profundas.
- Conocer el proceso involucrado en el habla humana.
- Estudiar procesamiento de las señales de voz.
- Diseñar un sistema robusto capaz de reducir los problemas de reverberación y ruido.
- Mostrar los resultados obtenidos y explicarlos basándonos en la información estudiada.

Y los objetivos con respecto a las competencias académicas desplegadas en el trabajo son:

- Desarrollar un mejor entendimiento de las redes neuronales y sus aplicaciones, para así poder lograr afrontar problemas en el campo de la inteligencia artificial.
- Obtener la capacidad de discriminar entre los algoritmos para tratar las señales de voz.
- Desarrollar el criterio necesario para trabajar con datos de audio.
- Obtener un conocimiento de las herramientas y recursos que existen actualmente para abordar problemas de aprendizaje profundo, además de poder analizar que herramientas son adecuadas para algunos problemas.

### 1.3. Estructura del Seminario

- **Introducción:**

En este capítulo introductorio se comenta sobre el tema a tratar, las motivaciones, intereses, objetivos con los cuales se planteo el presente seminario.

- **Estado del Arte:**

Este capítulo muestra los trabajos e investigaciones ya realizadas, además de algunas aplicaciones que motivaron al presente seminario y además las investigaciones mostrarán el interés del problema planteado.

- **Redes Neuronales:**

En este capítulo daremos una introducción a las redes neuronales de manera general, además veremos los tipos de redes existentes y nos enfocaremos más en las redes neuronales recurrentes.

- **Procesamiento de la señal de voz**

En este capítulo conoceremos más el proceso del ingreso de la señal a nuestra red como. También describiremos los algoritmos usados en este proceso.

- **Resultados:**

Se mostrarán los resultados obtenidos en las pruebas de los optimizadores además de describir los resultados.

- **Conclusiones y Trabajo Futuro:**

En este capítulo se plantean las conclusiones y se detalla algunos inconvenientes encontrados durante el trabajo. Además que se comprueba la teoría descrita en el capítulo 3.



# Capítulo 2

## Estado del Arte

En este capítulo se describirán las investigaciones anteriores con relación al Aprendizaje Automático, además de sus aplicaciones. También se verán algunas investigaciones referente al reconocimiento de voz y los algoritmos usados para estas tareas.

Este trabajo también presentará investigaciones referentes a Aprendizaje Profundo, exclusivamente nos enfocaremos a la Redes Neuronales Convolucionales(CNN), ya que son parte del tema de estudio en la presente investigación.

### 2.1. Aprendizaje Automático

El uso del Aprendizaje Automático representa una gran ventaja para empresas que manejan gran cantidad de datos debido a que permiten descubrir patrones y analizar los datos.

#### 2.1.1. Uso de redes neuronales para encontrar el rendimiento de una GPU

Un equipo conformado por investigadores [1]de AMD y The University of Texas at Austin, fueron quienes propusieron el uso de redes neuronales para predecir el rendimiento de una GPU. En la actualidad existen empresas dedicadas a la creación de GPUs, en el proceso una parte fundamental es la verificación del rendimiento de las GPUs. Actualmente existen simuladores

conocidos como GPGPU-SIM que permiten realizar estimaciones precisas pero estos presentan algunas dificultades como el tiempo empleado en configurarlos en base al hardware real, no obstante, este proceso se encuentra propenso a errores.

### **2.1.2. Handshape recognition for Argentinian Sign Language using ProbSom**

Investigadores de la Universidad de La Plata, en Argentina conformado por Franco Ronchetti, Facundo Quiroga, César Estrebou, y Laura Lanzarini[2], desarrollaron un sistema que permite el reconocimiento de lenguaje de señas argentino. Esta investigación fue realizada usando una técnica llamada ProbSom, esta puede ser comparada con otros métodos como las Máquinas de Soporte Vectorial, Bosques Aleatorios y Redes Neuronales.

## **2.2. Aprendizaje Profundo**

Dentro del área de Aprendizaje Automático encontramos Deep Learning o Aprendizaje Profundo el cual consiste en un conjunto de algoritmos que modela abstracciones de alto nivel.

En esta sección hablaremos de un paper que nos sirvió de una introducción al campo del aprendizaje profundo.

### **2.2.1. Deep Machine Learning - A New Frontier in Artificial Intelligence**

Este trabajo de investigación fue realizado por investigadores Thomas Karnowski, Derek Rose - Oak Ridge National Laboratory y Itamar Arel - University of Tennessee [3], el objetivo principal de este trabajo fue presentarnos el aprendizaje profundo como un camino para la imitación del cerebro humano y sus principales cualidades como el reconocimiento de objetos, rostros, etc.

En este paper presenta una introducción a los temas de *Convolutional Neural Network*(CNN) y *Deep Belief Network*, nos describe a las CNN como una familia de redes neuronales multicapas que fueron diseñadas para tratar datos de dimensionalidad 2 como lo son las imágenes y los videos.

Por otro lado, también nos muestra las aplicaciones del aprendizaje profundo como: análisis de documentos, detección de voz, rostro, procesamiento natural del lenguaje, etc.

La aplicación de la inteligencia artificial no solo despierto en los investigadores, también existen algunas empresas privadas que apoyan el campo del Aprendizaje Profundo con el objetivo de buscar sus aplicaciones comerciales, entre estas empresas tenemos a: Numenta y Binatix.

### **2.2.2. On Optimization Methods for Deep Learning**

Un equipo de la Universidad de Standford realizó unas pruebas con el objetivo de encontrar métodos adecuados para un entrenamiento en aprendizaje profundo. El equipo se percató de lo común que resulta el uso de gradiente de descenso estocástica (SGD por sus siglas en inglés) en aprendizaje profundo . Se realizaron pruebas con otros métodos de optimización como la gradiente conjugada y Limited memory BFGS(L-BFGS) los cuales permitieron acelerar el proceso de entrenamiento de algoritmos de Aprendizaje Profundo mostrando en su mayoría mejores resultados que el SGD. “Usando L-BFGS el modelo CNN alcanza el 0.69 % en el estándar del MNIST dataset.”[5]

## **2.3. Reconocimiento de Voz**

### **2.3.1. Review of Algorithms and Applications in Speech Recognition System**

Este trabajo fue realizado por CR Rashmi del *Cork Institute of Technology* (CIT) en la investigación se describe el reconocimiento del habla como

un método poder realizar distintas aplicaciones como: reconocimiento del hablante (Identificación Biométrica), emociones, acento, etc. Además se presentan distintos algoritmos que usan transformada de Fourier y modelos probabilísticos que son aplicados a tareas de reconocimiento de voz.

Esta investigación se centra en los algoritmos para la extracción de características y coincidencia de patrones.

Entre principales algoritmos para la extracción de características que muestran tenemos: RCC, MFCC, LPC, etc. Siendo el MFCC uno de los mejores para realizar tareas de reconocimiento del hablante. Por otro lado en coincidencia de patrones tenemos algoritmos como VQ, HMM, SVM, MLP, GMM, etc. Para tareas de reconocimiento de emociones y géneros destaca el GMM.

### 2.3.2. SPEECH RECOGNITION WITH DEEP RECURRENT NEURAL NETWORKS

Esta investigación realizada por los investigadores Alex Graves, Abdel-rahman Mohamed y Geoffrey Hinton de la Universidad de Toronto. El principal objetivo de esta investigación fue utilizar las redes neuronales recurrentes para el reconocimiento de fonemas utilizando el conjunto de datos TIMIT, el uso de las redes neuronales resulta adecuado debido a la naturaleza dinámica del habla.

El tipo de entrenamiento utilizado fue *end-to-end training* además se utilizan distribuciones diferenciales para todas las posibles salidas fonéticas. Entre los métodos estudiados para estas distribuciones de salida tenemos *Connectionist Temporal Classification (CTC)* este método decide si emitir una etiqueta de acuerdo al fonema identificado o no emitirla.

“Las redes neuronales entrenadas con CTC son generalmente bidireccionales para asegurar que la distribución de salida dependa únicamente de la secuencia de entrada”. Otro método estudiado en esta investigación de RNN transducir el cual predice un fonema dado uno previo. En la experimentación fueron usados 2 reguladores *parada temprana* y *pesos de ruidos*. “CLC se obtiene un

porcentaje de error de 23.9 % a 18.4 % a medida que se aumentan los niveles ocultos de la red. ”

### 2.3.3. EFFICIENT CEPSTRAL NORMALIZATION FOR ROBUST SPEECH RECOGNITION

Esta investigación estuvo a cargo de Fu-Hua Liu, Richard M. Stern, Xuedong Huang y Alejandro Acero del departamento de ingeniería eléctrica e informática de la Universidad de Carnegie Mellon. El objetivo de esta investigación fue comparar los procedimientos basados en cepstrum usados en el reconocimiento de voz sobre variedad de entornos acústicos.

Para los autores “Los estudios muestran que los sistemas de reconocimiento de voz que son diseñados para ser independientes del hablante funcionan de manera incorrecta cuando se prueban distintos micrófonos o entornos con los cuales fueron entrenados ”. Una solución a este problema es la aplicación de técnicas de normalización cepstral como *SNR-Dependent Cepstral Normalization (SDCN)*, *Fixed Codeword-Dependent Cepstral Normalization (FCDCN)* y *Multiple fixed codeword-dependent cepstral normalization (MFCDCN)*.

Entre el FCDCN y MFCDCN este último resulta ser mejor debido a que no requiere del entrenamiento del específico como lo hace el FCDCN.

### 2.3.4. DELTA-SPECTRAL CEPSTRAL COEFFICIENTS FOR ROBUST SPEECH RECOGNITION

El presente paper fue realizado por Kshitiz Kumar , Chanwoo Kim y Richard M. Stern del departamento de ingeniería eléctrica e informática de la Universidad de Carnegie Mellon. En esta investigación se busca diseñar un sistema de reconocimiento de voz más robusto mediante el uso de las características delta-espectrales. En palabra de los autores “ *A pesar que las características delta cepstrales capturan la información dinámica y mejoran la precisión del reconocimiento de voz no son robustos contra el ruido y reverberación.*”

### 2.3.5. Voice Recognition Algorithms using Mel Frequency Cepstral Coefficient (MFCC) and Dynamic Time Warping (DTW) Techniques

Esta investigación fue realizada por Lindasalwa Muda, Mumtaj Begam y I. Elamvazuthi, en esta se describen los principios involucrados en el reconocimiento de voz como la extracción de características y patrones. Al igual que otras investigaciones los autores afirman *“La voz es una señal de infinita información. Un análisis directo y sintetizado es requerido para la gran cantidad de señal contenida en la señal.”*

El reconocimiento de voz puede ser dividido en 2 fases una fase de entrenamiento en que el hablante provee información o muestras de su voz y una fase de testeo donde se verifica que la voz de entrada coincida con la del hablante del proceso de entrenamiento. Los investigadores utilizan MFCC para la extracción de características y DTW para reconocimiento de los patrones. En las pruebas de identificación se logró encontrar una distorsión óptima en DTW que permitió reconocer al hablante.

### 2.3.6. Convolutional Neural Networks for Speech Recognition

Entre los distintos modelos existentes en redes neuronales profundas ha surgido la necesidad de realizar modelos híbridos como *Deep Neural Network-Hidden Markov Model (DNN-HMM)* y *Gaussian Mixture Model - Hidden Markov Model (GMM-HMM)*. La presente investigación encontró que la primera es más robusta debido a la capacidad que poseen las redes neuronales al momento de modelar correlaciones complejas de las características de la voz.

Los resultados mostraron que usando CNN se obtuvo una mejora de 6-10 % en tareas de phone recognition y búsqueda de voz en un gran vocabulario.

### **2.3.7. TIME-FREQUENCY CONVOLUTIONAL NETWORKS FOR ROBUST SPEECH RECOGNITION**

Este estudio usa a las redes neuronales convolucionales profundas(DCNN) para generar una arquitectura más robusta contra el ruido y otras variaciones del entorno. DCNN usa los filtros de convolución para así poder remover las distorsiones cross-spectral una cualidad de este tipo de red es que no utiliza la convolución sobre el tiempo. Por lo cual esta convolución es trata en esta investigación definiendo un esquema llamado time-frequency convolutional network (TFCNN), esta red aplica 2 capas de convolución paralelas una para la frecuencia y otra para el tiempo.

En las pruebas realizadas se nota una mejora al probar con ruidos, canales y datos dañados con reverberación a comparación del uso de DCNN.

## **2.4. Conclusiones**

A medida que tratamos muchos problemas vemos la necesidad de encontrar optimizadores adecuados para los diferentes tipos de problemas. En el área de Aprendizaje Profundo comúnmente se trabaja en el campo de reconocimiento de imágenes.

A pesar de las mejoras mediante el uso de GPUs este tipo de problemas necesitan soluciones óptimos para obtener un mejor rendimiento. Métodos como Nesterov Momentum, RMSProp y Adam surgen como principales opciones para realizar optimizaciones de la gradiente de descenso.

# Capítulo 3

## Redes Neuronales Artificiales

En este capítulo daremos una introducción a las redes neuronales artificiales veremos su uso en el aprendizaje automático para tareas de clasificación y además estudiaremos 2 tipos especiales de redes neuronales como son las *redes convolucionales y recurrentes*.

En este seminario se dará más énfasis a las redes recurrentes y su aplicación en el procesamiento de voz para lograr la tarea de conversión voz a texto.

### 3.1. Conceptos básicos

A continuación describiremos algunos conceptos necesarios para el entendimiento de las redes neuronales artificiales más adelante se mostrarán nuevos de acuerdo al tipo de red.

#### 3.1.1. Neuronas

En la biología, la neurona es conocida como la unidad fundamental del cerebro humano, el cual está compuesto por millones de neuronas interconectadas entre si(sinapsis). El trabajo de las neuronas consiste en recibir información, procesarla y enviarla a otras neuronas.

Este modelo fue copiado en 1943 por Warren S. McCulloch y Walter H. Pitts para poder diseñar un neurona artificial que es análoga a las neuronas del cerebro humano, esta neurona artificial tomará una cantidad  $n$  de entradas  $x_1, x_2, x_3, \dots, x_n$  las entradas serán multiplicadas(producto interno) por pesos



$w_1, w_2, w_3, \dots, w_n$  además se puede añadir una constante que llamaremos bias( $b$ ) para producir un salida.

La entrada a la neurona será la suma total de los productos  $z = \sum_{i=1}^n w_i x_i + b$ , el valor de  $z$ , esta se evaluará con una función  $f$  de tal forma que nuestra salida será  $y = f(z)$ .

En la ecuación 3.1 observamos la misma salida expresada en forma vectorial para nuestros vectores  $x = [x_1 x_2 x_3 \dots x_n]$  y  $w = [w_1 w_2 w_3 \dots w_n]$

$$y = f(x \cdot w + b) \quad (3.1)$$

### 3.1.2. Funciones de Activación

La función  $f$  mencionada anteriormente es una función no lineal, conocida como **función de activación**.

La tarea principal de la función de activación es introducir no linealidad a la salida de una neurona. Esto es importante debido a que la vida real no trabajamos solo con datos lineales y de esta forma la neurona puede aprender representaciones no lineales.

Entre funciones de activación tenemos algunas comúnmente usada como:

- **Sigmoid:** Toma un valor real, y lo transforma en un valor en el rango de 0 a 1.

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

- **tanh:** Toma por entrada un valor real y lo transforma a un número en el rango de -1 a 1.

$$\tanh(x) = \frac{2}{1+e^{-x}} - 1$$

- **ReLU:** o Unidad lineal rectificada es una función que para valores menores que 0 asigna 0 y para valores mayores

$$f(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases}$$




FIGURA 3.1: Funciones de activación

Fuente: <https://ujjwalkarn.me>

### 3.1.3. Redes Neuronales Artificiales

Las redes neuronales artificiales(ANN) toman la arquitectura del cerebro como inspiración para la construcción de sistemas inteligentes. Actualmente son la base para el desarrollo de la inteligencia artificial.

Una red neuronal está constituida por las uniones de neuronas.

En la figura 3.10 podemos ver la comparación entre una neurona biológica y un artificial etiquetadas con A y B respectivamente. Además observamos que las redes neuronales artificiales (etiqueta D) imitan el la unión biológicas de las neuronas o sinapsis(Etiqueta C).




FIGURA 3.2: Redes neuronales biológicas y artificiales

Fuente: <https://medium.com>

## 3.2. Redes Neuronales FeedFoward

Estas redes fueron de las primeras y más simples. Contienen múltiples neuronas (nodos) ordenadas en capas de modo que los nodos en capas adyacentes se conectan. Cada una de estas conexiones poseen un peso asociado a dicha conexión.

En la figura 3.3 mostramos el esquema de Redes FeedFoward con sus distintas capas(layer).




FIGURA 3.3: Esquema de Redes Neuronales FeedFoward

Fuente: <https://uijwalkarn.me>

- **Nodo de entrada(Input Node):** Proveen información a la red. En conjunto representan la capa de entrada, ningún cálculo es realizado en esta capa solo se transfiere la información a la capa oculta.
- **Nodo Oculto(Hidden Node):** El trabajo de los nodos ocultos es calcular y transferir la información hacia a el nodo de salida. Una Red FeedFoward tiene solo una capa de entrada y una salida pero puede tener múltiples capas ocultas.
- **Output Node:** Su tarea principal es realizar cálculos y transferir la información fuera de la red.

En las Redes Neuronales FeedFoward, la información solo se propaga en una dirección hacia *adelante* desde los nodos de entradas pasando por los nodos ocultos hacia los nodos de salida. No existen ciclos en este tipo de red.

Dentro de las redes neuronales FeedFoward tenemos algunos ejemplos:

- **Perceptron Simple:** Es un red prealimentada simple que no posee capa oculta. Solo puede aprender de funciones lineales.
- **Perceptron Multicapas:** Esta red posee una o más capas ocultas. Este perceptron puede aprender de funciones no lineales.
- **Redes neuronales de convolución:** Este tipo de redes neuronal será explicada más adelante en el capítulo.

### 3.2.1. Algoritmo de propagación hacia atrás

El algoritmo de propagación hacia atrás trata de aprender de los errores, en el aprendizaje supervisado los conjuntos de entrenamiento se encuentran etiquetados. Por lo cual podemos sabemos la salida esperada.

El algoritmos se aplica de la siguiente forma:

1. Se toma un ejemplo y se asignan pesos aleatorios a todas las conexiones de la red. Luego por medio de las conexiones y funciones de activación se calcula la salida en las capas ocultas y de salida.
2. Se calcula el error total y se propagan estos errores hacia atrás a través de la red y se calcula la gradiente, luego se usan métodos como gradientes de descenso para ajustar los pesos y reducir el error en la capa de salida.
3. Se repite el proceso con los otros ejemplos

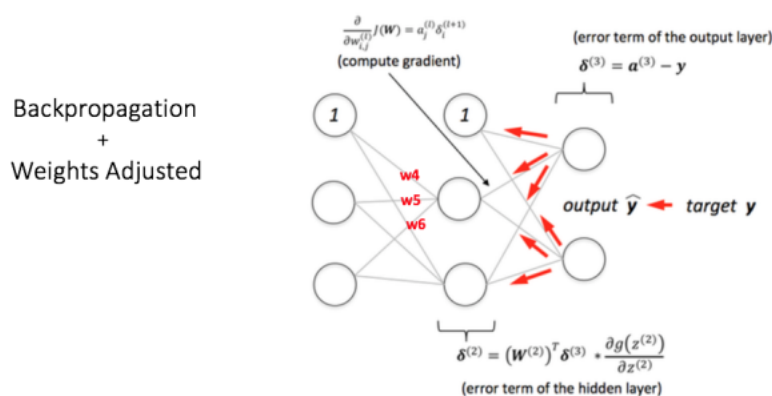


FIGURA 3.4: Propagación hacia atrás

Fuente: <https://ujjwalkarn.me>

### 3.3. Redes Neuronales Convolucionales

Las CNN son un tipo de Redes Neuronales FeedFoward que son especiales para procesar datos como imágenes las cuales son más difíciles de tratar en una red neuronal tradicional, como por ejemplo en el caso del perceptron multicapas.

El término *convolucional* hace referencia a la operación lineal matemática usada. Las redes neuronales convolucionales usan esta operación para aprender de las características de mayor orden presente en los datos. La primera CNN fue creada por Yann LeCun. Estas redes neuronales fueron inspiradas en la corteza visuales de los animales. Las células de la corteza visual, estas se activan para realizar tareas como el reconocimiento de patrones.

Entre sus usos más comunes tenemos el reconocimiento de imágenes y lenguaje natural.

#### 3.3.1. Estructura de una imagen

Debido a que las redes neuronales convolucionales son usadas comúnmente con imágenes, es importante conocer cual es la estructura de una imagen y cómo es que la computadora comprende y utiliza esta información.

Las imágenes están constituidas por una sucesión de píxeles, podemos entender el pixel como la menor unidad homogénea en color de una imagen digital. Teniendo este concepto, podemos dividir la información de una imagen de la siguiente forma:

- **Width:** El ancho de la imagen medido en pixeles
- **Height:** El alto de la imagen medida en pixeles.
- **Canales RGB:** Estos canales contiene la información de los colores y profundidad de una imagen. Este canal guarda la información en tres canales Red, Green y Blue.




FIGURA 3.5: Estructura de la imagen de entrada  
Fuente: *Deep Learning by Adam Gibson, Josh Patterson*

Teniendo en cuenta esta forma de dividir la información de una imagen podemos resaltar la ventaja de usar Redes convolucionales en lugar de usar una red neuronal multicapas.

Las redes multicapas toman un vector de una dimensión como entrada, si quisiéramos entrenar un perceptron multicapas con imágenes de 32x32 píxeles y con 3 canales RGB necesitaríamos crear 3072 pesos ( $w_i$ ) para una sola neurona en la capa oculta. Esta generación excesiva de peso hace que la tarea resulte complicada usando redes multicapas.

De esta forma surge la idea de recurrir a un tiempo tipo de redes neuronales que faciliten la tarea sin consumir muchos recursos.

### 3.3.2. Capas de una CNN

Las redes neuronales convoluciones pueden ser divididas en distintas capas, cada una de ellas con una tarea específica para el tratamiento de la información. En esta sección describiremos cada una de estas capas.

### Input layer

Esta capa es la encargada de cargar y almacenar la información de las imágenes para luego procesarlas en la red. Esta información contiene detalles de ancho, alto en píxeles y el número de canales de imagen. Las entradas de esta capa corresponden a la imagen vista en la figura 3.5.

### Convolutional layers

Es una de las capas más importante en el diseño de las CNNs, esta capa es la encargada de transformar la entrada(imagen o convolución anterior) usando las conexiones de las neuronas en capas anteriores.

Para entender más a fondo esta capa debemos definir la operación de *convolución*.

La *convolución* es una operación matemática que describe una regla de como fusionar 2 conjuntos de información. “Esta operación tiene importancia en campos como la matemática y la física debido que permite definir un puente entre el dominio del espacio/tiempo y el dominio de la frecuencias a través del uso de la transformada de fourier. La convolución toma una entrada, aplica un kernel de convolución y nos da un mapa de características como salida ”[15] .

Las convoluciones son usadas principalmente como un detectores de características cuyas entradas son la capa de entrada u otra convolución. En la figura 3.6 observamos la operación de convolución que por medio del uso de un kernel o filtro de convolución extrae características de la imagen, por ejemplo detalles como bordes de una imagen.

Haciendo analogía con los pesos en las redes neuronales convencionales, las redes convolucionales poseen el *filtro o kernel* , esto resulta beneficioso, ya que no se tendrá definir un peso para cada neurona.

El kernel de la figura 3.6 será desplazado a lo largo de las dimensiones espaciales. Durante el desplazamiento, el kernel se multiplicará por los datos de entrada dentro de su limite, produciendo una sola salida al mapa de características.




FIGURA 3.6: Operación de convolución

Fuente: [www.openresearch.ai](http://www.openresearch.ai)

Las capas convolucionales aplican transformaciones o funciones de activación al conjunto de entrada, luego el mapa de activación generado se apilará a lo largo de dimensión de profundidad para construir el volumen de salida.

### Componentes de la capa de convolución.

Las capas convolucionales poseen parámetros e hiperparámetros. La gradiente de descenso tiene la función de entrenar a estos parámetros de modo que las clases sean consistentes con las etiquetas en el conjunto de entrenamiento. Entre estos parámetros tenemos: **Filtros**

Los filtros son una función que posee ancho(width) y alto (height) más pequeños que la entrada. Los filtros son aplicados a través de del ancho y alto de la entrada, pero también pueden ser aplicados a lo largo de la profundidad.



**Hiperparámetros de una capa de convolución.**

A continuación veremos algunos hiperparámetros que determinan la disposición espacial y tamaño del volumen de salida de una capa convolucional.

- **Filter size:** Cada filtro es pequeño con respecto al ancho(width) y alto(height) del la capa anterior. Por ejemplo podemos tener un filtro de tamaño  $[5 \times 5 \times 3]$ , lo representa 5 de ancho x 5 de alto x 3 de los canales RGB.
- **Output depth:** Este hiperparámetro controla el número de neuronas en la capa convolucional que están conectadas al mismo del volumen de entrada. Este parámetro puede ser elegido manualmente.
- **Stride:** Se encarga de configurar el tamaño de desplazamiento de la ventana de filtro. Cada filtro aplicado a la columna de entrada asignará más profundidad en el volumen de salida. Un stride grande creará un volumen de salida más grande y uno valor pequeño obtendrá un volumen menor.
- **Zero-padding:** Con este parámetro se puede controlar el volumen de salida. Es usado para mantener el tamaño espacial de entrada en la salida.

**Pooling layers**

Este tipo de capas se encuentran entre las capas convolucionales. Se encarga de reducir el tamaño espacial(ancho,alto) de los datos de representación. Esta capa reduce la representación de los datos progresivamente a través de la red y ayuda a controlar el *overfitting*.

Esta capa utiliza la operación  $\max()$  para cambiar el tamaño de los datos de entrada espacialmente, a esta operación se le conoce como max pooling. Esta funciona de siguiente forma toma un filtro de  $n \times n$ , y la operación  $\max$  toma el mayor de los números en el área de filtro.

Por ejemplo en caso tener una imagen de entrada  $32 \times 32$  píxeles y se aplica un filtro de  $2 \times 2$ , como resultado obtendremos una salida de  $16 \times 16$  píxeles. Esto reduce cada segmento de profundidad en el volumen de entrada por un factor de 2.

### Fully Connected Layers

Esta capa se calcula el puntaje de las clases que usaremos como salida de red, esta será la encargada de reconocer a que clase pertenece una imagen de prueba de acuerdo a su puntaje o probabilidad. Las dimensiones del volumen de la salida son  $[1 \times 1 \times N]$ , donde el valor de  $N$  corresponde al número de clases de salida que se están evaluando. En el caso del MNIST (dataset para reconocimiento de dígitos), el valor de  $N$  es igual a 10, número que corresponde a los 10 dígitos distintos que posee el dataset(0, ..., 9).

Esta capa tiene conexión entre todas sus neuronas y las de la capa anterior. Esta capa realiza las transformaciones del volumen de datos de entrada. Estas son funciones de activación en el volumen de entrada y los parámetros (pesos y bias de las neuronas).

### 3.3.3. Arquitecturas conocidas

Actualmente existen algunas arquitecturas de CNN ya diseñadas que son aplicadas para el trabajo de reconocimiento de imágenes.

El proyecto ImageNet, posee una gran base de datos de imágenes. Este proyecto realizó una competición llamada *ImageNet Large Scale Visual Recognition Challenge (ILSVRC)* donde compiten distintos programas de software para detectar y clasificar objetos.

A continuación mostraremos algunas de las arquitecturas más importante de esta competencia:

- **LeNet-5 (1998)** “Arquitectura propuesta por LeCun, consiste 2 capas de convolución, activación y capas pooling seguidas por a fully conected layer”[16]
- **AlexNet (2012)** Fue propuesta por Alex Krizhevsky, esta arquitectura posee 5 capas de convolución seguida por 3 fully connected layers.
- **VGGNet (2014)** Fue desarrollada para Sigmoyan y Zisserman para la competición ILSVRC. “VGG consta de 16 capas convolucionales y es muy atractivo debido a su arquitectura uniforme. Consta de convoluciones de 3x3 y utiliza múltiples filtros ”[17]

### 3.4. Redes Recurrentes

Las redes neuronales recurrentes aparecieron en los años 1980s, actualmente se han desarrollado más estudios debido a la mejora de hardware. Son utilizadas principalmente para tratar con una información de secuencia, por ejemplo series de tiempo, audio, sentencia de oraciones, etc.

La principal diferencia de la redes con las redes neuronales feed-foward es que en las neuronas de las redes recurrentes las salidas regresan a la entrada de esta manera mantiene información de un estado anterior. Esto permite que nuestro modelo sea cambiante cada vez que este se alimente con una secuencia nueva.

Dentro de una capa recurrente se tiene los siguientes tipos de conexiones :

- **Entrantes:** Son aquellas que emanan de la capa previa.
- **Salientes:** Estas conexiones son dirigidas a todas las neuronas de las capas consecuentes.
- **Recurrentes:** se encargan de propagar la información entre las neuronas de las misma capa.




FIGURA 3.7: Neurona Recurrente

Fuente: <https://medium.com>

Es posible representar a la redes recurrentes como si fueran redes feed-fowards esto lo realizamos *desenrollando* la neurona como vemos en la figura 3.8 el  $x_t$  representa un estado final de esta forma podemos representar la red como un conjunto de estados a través de un lapso de tiempo. En esta forma las técnicas de backpropagation pueden ser usadas en la redes recurrentes.




FIGURA 3.8: Versión desenrollada

Fuente: <https://medium.com>



## **Capítulo 4**

### **Procesamiento señal de voz**

# **Capítulo 5**

## **Resultados**

# **Capítulo 6**

## **Conclusiones y Trabajo Futuro**

En este capítulo se describirán las conclusiones generales

### **6.1. Conclusiones**

### **6.2. Trabajo Futuro**



# Bibliografía

- [1] John Nickolls William J. Dally. The gpu computing era. *IEEE Micro*, 30:56–69, 2010.
- [2] César Estrebou Franco Ronchetti, Facundo Quiroga and Laura Lanzarini. Handshape recognition for argentinian sign language using probsom. *JCST*, 16(1):1–5, 2010.
- [3] Derek Rose Itamar Arel and Thomas Karnowski. Deep machine learning - a new frontier in artificial intelligence research [research frontier]. *IEEE Computational Intelligence Magazine*, pages 1–7, 2010.
- [4] Vadim Smolyakov. Neural network optimization algorithms a comparison study based on tensorflow. [https://medium.com/@siddharthdas\\_32104/cnns-architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5](https://medium.com/@siddharthdas_32104/cnns-architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5), Ene 2017. Accessed on 2018-06-11.
- [5] Adam Coates Abhik Lahiri Bobby Prochnow Quoc V. Le, Jiquan Ngiam and Andrew Y. Ng. On optimization methods for deep learning. *International Conference on Machine Learning 2010*, pages 1–8, 2010.
- [6] Diederik P. Kingma and Jimmy Lei Ba. Adam : A method for stochastic optimization. *ICLR*, pages 1–15, 2015.
- [7] Timothy Dozat. Incorporating nesterov momentum into adam. *ICLR*, pages 1–3, 2016.
- [8] Machine learning 101 | supervised, unsupervised, reinforcement and beyond. <https://medium.com/deep-math-machine-learning-ai/different-types-of-machine-learning-and-their-types-34760b9128a2>, Sep 2017. Accessed on 2018-05-11.

- [9] David Fumo. Types of machine learning algorithms you should know. <https://towardsdatascience.com/types-of-machine-learning-algorithms-you-should-know-953a08248861>, Jun 2017. Accessed on 2012-05-11.
- [10] Jason Brownlee. Linear regression for machine learning. <https://medium.com/deep-math-machine-learning-ai/different-types-of-machine-learning-and-their-types-34760b9128a2>, Mar 2016. Accessed on 2018-05-12.
- [11] Essentials of machine learning algorithms (with python and r codes). <https://www.analyticsvidhya.com/blog/2017/09/common-machine-learning-algorithms/>, Sep 2017. Accessed on 2018-05-14.
- [12] K nearest neighbors - classification). [http://www.saedsayad.com/k\\_nearest\\_neighbors.htm](http://www.saedsayad.com/k_nearest_neighbors.htm). Accessed on 2018-05-15.
- [13] Naive bayesian). [http://www.saedsayad.com/naive\\_bayesian.htm](http://www.saedsayad.com/naive_bayesian.htm). Accessed on 2018-05-15.
- [14] Sunil Ray. 6 easy steps to learn naive bayes algorithm (with codes in python and r). <https://www.analyticsvidhya.com/blog/2017/09/naive-bayes-explained/>, Sep 2017. Accessed on 2018-05-13.
- [15] Josh Patterson and Adam Gibson. Major architectures of deep networks. In *Deep Learning A Practitioner's Approach*, pages 132–135. O'Reilly Media, 2017.
- [16] Adrian Rosebrock. Lenet – convolutional neural network in python. <https://www.pyimagesearch.com/2016/08/01/lenet-convolutional-neural-network-in-python>, Ago 2016. Accessed on 2018-06-15.
- [17] Siddharth Das. Cnn architectures: Lenet, alexnet, vgg, googlenet, resnet and more .... [https://medium.com/@siddharthdas\\_32104/cnns-](https://medium.com/@siddharthdas_32104/cnns-)

architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5, Nov 2017. Accessed on 2018-06-15.

- [18] Elad Hazan John Duchi and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research* 12, pages 1–2, 2011.



## **Apéndice A**

### **Arquitectura de la red y Resultados obtenidos**

#### **A.1. Resultados de precisión de entrenamiento**